

**LOCALIZAÇÃO DE DISPOSITIVOS MÓVEIS EM
REDES WIFI
USANDO VARIAÇÃO POTÊNCIA DE
TRANSMISSÃO E KNN**

HELMER AUGUSTO DE SOUZA MOURÃO

LOCALIZAÇÃO DE DISPOSITIVOS MÓVEIS EM
REDES WIFI
USANDO VARIAÇÃO POTÊNCIA DE
TRANSMISSÃO E KNN

Dissertação apresentada ao Programa de
Pós-Graduação em Informática do Instituto
de Computação da Universidade Federal do
Amazonas como requisito parcial para a ob-
tenção do grau de Mestre em Informática.

ORIENTADOR: HORACIO A. B. FERNANDES DE OLIVEIRA

Manaus

Abril de 2013

© 2013, Helmer Augusto de Souza Mourão.
Todos os direitos reservados.

de Souza Mourão, Helmer Augusto

Localização de Dispositivos Móveis em Redes WiFi Usando
Variação Potência de Transmissão e kNN / Helmer Augusto de
Souza Mourão. — Manaus, 2013

xx, 61 f. : il. ; 29cm

Dissertação (mestrado) — Universidade Federal do Amazonas
Orientador: Horacio A. B. Fernandes de Oliveira

1. Computação — Teses. 2. Redes — Teses. I. Orientador.
II. Título.

[Folha de Aprovação]

Quando a secretaria do Curso fornecer esta folha,
ela deve ser digitalizada e armazenada no disco em formato gráfico.

Se você estiver usando o `pdflatex`,
armazene o arquivo preferencialmente em formato PNG
(o formato JPEG é pior neste caso).

Se você estiver usando o `latex` (não o `pdflatex`),
terá que converter o arquivo gráfico para o formato EPS.

Em seguida, acrescente a opção `approval={nome do arquivo}`
ao comando `\ppgccufmg`.

Se a imagem da folha de aprovação precisar ser ajustada, use:
`approval=[ajuste][escala]{nome do arquivo}`
onde *ajuste* é uma distância para deslocar a imagem para baixo
e *escala* é um fator de escala para a imagem. Por exemplo:
`approval=[-2cm][0.9]{nome do arquivo}`
desloca a imagem 2cm para cima e a escala em 90%.

*“A felicidade mantém você doce;
Dores mantém você humano;
Quedas te mantêm humilde;
Provações te mantêm forte;
Mas só Deus te mantêm prosseguindo.”*
(Autor desconhecido)

Resumo

A localização de um dispositivo é uma informação que pode ser muito importante em varias áreas da computação como em robótica, computação móvel e computação sensível ao contexto. O desenvolvimento de serviços baseados em localização aplicados em redes sem fio têm sido alvo de pesquisas recentes, uma vez que abre perspectivas para novas aplicações e agregam valor a estas redes. Nestas aplicações a posição do dispositivo no ambiente é uma informação relevante para a aplicação. A área de localização é uma área muito abrangente sobretudo quando se trata de localização em ambientes internos, isso se deve a características desse tipo de ambiente que dificultam os sistemas de localização tradicionais. Os problemas relacionados a localização e posicionamento nesse tipo de ambientes podem ser atacados de diferentes formas, dependendo da aplicação e precisão desejada. Uma alternativa que tem sido utilizada é o uso de infraestrutura de redes WiFi (Wireless Fidelity) para esse fim, isso se deve a fatores como a grande disseminação de dispositivos móveis que dispõe dessa tecnologia e pela evolução e generalização das redes WiFi tanto em ambiente empresarial como acadêmico, com isso muitas organizações atualmente optam pela flexibilidade e mobilidade das redes WiFi. Tanto em ambientes fechados dentro de edifícios como em exteriores encontram-se facilmente pontos de acesso WiFi, que através da sua resultante cobertura tornam possível a instalação de um sistema capaz de localizar dispositivos móveis dentro de uma rede WiFi. Dessa grande disponibilidade surge a vantagem de sua utilização já que é uma tecnologia muito difundida e de fácil obtenção.

Sistemas de localização de dispositivos móveis em ambientes internos são geralmente baseados na potência de recepção de pacotes em um conjunto de roteadores WiFi. Dentre as soluções de localização mais precisas estão as baseadas em treinamentos, que utilizam informações previamente coletadas de potências de sinais recebidos (RSSI - *Received Signal Strength Indication*) para permitir que um classificador, como o kNN (*k-Nearest Neighbor*), estime a posição. Em tais abordagens os pacotes são enviados pelos dispositivos móveis sempre com a mesma potência de transmissão. Neste trabalho, vamos além e propomos o envio dos pacotes em diferentes potências

de transmissão, para que a característica de queda do sinal possa também ser levada em consideração pelo classificador. Os resultados obtidos foram animadores e mostraram ganhos significativos quando comparado às abordagens tradicionais encontradas na literatura obtendo, em algumas configurações, erros menores que 1 m em 96% dos casos.

Palavras-chave: redes, Wi-Fi, localização.

Abstract

The localization of a device is information that can be very important in many areas of computing as robotics, mobile computing and context-sensitive computing. The development of location-based services applied in wireless networks have been the focus of recent research, because open perspectives for new applications and add value to these networks. In these applications the position of the device in the environment is information relevant to the application.

Finding the location of a device can be done in several ways especially when it comes to indoors environments, this is because the characteristics of this type of environment difficult the operation traditional localization systems. Problems related to localization and positioning in such environments can be attacked in different ways, depending on the application and desired accuracy.

An alternative that has been used is the WiFi infrastructure for this purpose, it is because factors such as the large availability of mobile devices that have this technology and the evolution and dissemination of WiFi networks in academic and business environments, with many organizations choose this, because the flexibility and mobility of this networks, so much inside buildings and outdoors are easy to find WiFi access points, which through its resulting coverage make it possible to install a system capable of locating mobile devices within a WiFi network this large availability comes the advantage of using a technology that is already availability and easy to obtain.

Indoor localization systems are usually based in the signal strength of packets received by a set of WiFi routers. Among the most precise solutions, are those based in trainment, that use previously recorded received signal strength indications (RSSI) to allow a classifier, such as kNN (k-Nearest Neighbor) to estimate the position. In these solutions, packets are sent by the mobile devices using the same transmission power. In this paper, we go further and propose the use of different transmission powers, so the information about the signal fading can be taken into consideration by the classifier. Our results clearly indicate significant improvement when compared to

the traditional solutions. In some configuration, our solution resulted in less than 1 m error in 96% of the cases.

Keywords: localization, Networks, Wi-Fi.

Lista de Figuras

2.1	Localização por Tempo de Chegada	10
2.2	Localização por Angulo de Chegada	12
2.3	Rede Neural Artificial (RNA).	19
2.4	Formas de <i>multipath</i>	23
4.1	Arquitetura do Sistema de Localização.	34
4.2	Funcionamento do SPoT.	35
4.3	Exemplo do kNN em duas dimensões.	36
4.4	Erro na Celula.	37
4.5	Cisco/Linksys WRT610N.	37
4.6	Coleta de Informações.	38
5.1	Resultados obtidos usando cinco roteadores.	43
5.2	Resultados obtidos usando três roteadores.	45
5.3	Resultados obtidos usando quatro roteadores.	46
5.4	Resultados obtidos variando as potências 3 a 3.	47
5.5	Resultados obtidos variando potências 2 a 2.	48
5.6	Resultados obtidos variando as potências 4 a 4.	49
5.7	Resultados obtidos variando a quantidade de potências.	49
5.8	Distribuição do erro por Posição SPoT-5P.	50
5.9	Distribuição do erro por Posição na Abordagem Convencional.	50

Lista de Tabelas

Lista de Acrônimos

AoA Angle of Arrival

FDA Função de Distribuição Acumulada

GNSS Global Navigation Satellite Systems

GPS Global Positioning System

kNN k-Nearest Neighbor

PA Pontos de Acesso

RFID Radiofrequency Identification

RNA Redes Neurais Artificiais

RSSI Received Signal Strength Indication

SPoT Sistema de Posicionamento com variação da Potência de Transmissão

SVM Support Vector Machine

TDoA Time Differences of Arrival

ToA Time of Arrival

WiFi Wireless Fidelity

Sumário

Resumo	ix
Abstract	xi
Lista de Figuras	xiii
Lista de Tabelas	xv
1 Introdução	1
1.1 Motivação	3
1.2 Definição do Problema	4
1.3 Objetivos Gerais e Específicos	4
1.4 Estrutura	5
2 Localização em ambientes internos (<i>indoor</i>)	7
2.1 Tipos de Localização	8
2.2 Tecnologias utilizadas em localização para ambientes internos	8
2.2.1 Localização em Redes WiFi	9
2.2.2 RFID	13
2.2.3 Infra-vermelho	14
2.2.4 Proximidade	14
2.2.5 Bluetooth	15
2.2.6 Zigbee	15
2.2.7 Conclusão	15
2.3 Algoritmos utilizados em localização para ambientes internos	16
2.3.1 Técnicas Geométricas	16
2.3.2 Técnicas <i>Fingerprinting</i> (Mapas de RSSI)	17
2.3.3 Redes Neurais Artificiais (RNA)	18
2.3.4 Maquinas de Vetores de Suporte (SVM - <i>Support Vector Machine</i>)	19

2.3.5	k-Nearest Neighbor (kNN)	20
2.3.6	Conclusão	21
2.4	Características do Problema de Localização em Redes WiFi	21
2.4.1	Interferência de Propagação de caminho Multiplo <i>multipath</i>	22
3	Trabalhos relacionados	25
3.1	Sistemas de localização usando diversas Tecnologias	25
3.2	Sistemas de Localização Usando RSSI e Fingerprinting	27
4	SPoT: Sistema de Posicionamento com Variação da Potência de Transmissão	33
4.1	Arquitetura do Sistema de Localização	33
4.2	Localização usando Variação da Potência de Transmissão	34
4.3	Configuração e Experimentos	37
4.3.1	Montando o Mapa de RSSI	38
5	Avaliação de Performance	41
5.1	Análise dos Resultados usando Cinco Roteadores	43
5.2	Análise dos Resultados usando Três e Quatro Roteadores	44
5.3	Análise dos Resultados usando diferentes combinações de Potências de Transmissão	45
5.4	Análise dos Resultados usando diferentes Quantidades de Potências de Transmissão	47
5.5	Análise do Acerto por Posição	48
6	Conclusões e Trabalhos Futuros	51
	Referências Bibliográficas	53

Capítulo 1

Introdução

Graças aos avanços nas tecnologias de hardware e comunicação sem fio, tornou-se possível o desenvolvimento de ambientes de computação pervasiva, onde os dispositivos de computação interagem com os usuários e o ambiente de forma transparente [Satyanarayanan, 2001]. Para isso ocorrer, é necessário que os dispositivos computacionais possam se comunicar e se auto configurar sem exigir muito conhecimento técnico dos usuários que irão utilizá-los tornando-se um ponto chave em para muitas aplicações [Martin et al., 2010].

Nos últimos anos tem-se observado a massificação dos dispositivos móveis que dispões de tecnologia WiFi no mercado consumidor tais quais *notebooks*, *netbooks*, aparelhos celulares e *smartphones* [Popov et al., 2008; Santos et al., 2011]. Isso, aliado ao aumento da capacidade de processamento e o surgimento de novas tecnologias de comunicação, possibilitou o desenvolvimento de aplicativos orientados a contexto [Moura, 2007], assim como uma série de possibilidades a serem exploradas e que tem influência em diversas áreas de pesquisa. Em tais aplicativos, um dos pontos essenciais é localizar o dispositivo no ambiente em que ele se encontra.

Uma das principais soluções para a localização/posicionamento é a utilização de receptores GPS (*Global Positioning System*), já disponível em muitos dos dispositivos móveis. Entretanto, tal sistema tem uma baixa performance em ambientes internos devido à falta de visada direta aos satélites, o que impede ou gera erros de localização inaceitáveis [Ni et al., 2004]. Portanto, em tais casos, um sistema de localização local é necessário.

Outro desafio seria que os sistemas móveis devem se ser o mínimo invasivos possível, através da obtenção das informações necessárias de forma imperceptível. Nesse aspecto, um sistema de localização que se aproveita da infraestrutura de rede WiFi já existente em edificios e locais públicos torna-se algo bastante desejável. Dentre as

principais soluções para localização em ambientes internos encontram-se as soluções baseadas em treinamentos como Bahl & Padmanabhan [2000]; Moura [2007]; Ni et al. [2004]; Jan & Lee [2003] Ekahau¹, que utilizam informações previamente coletadas de potências de sinais recebidos (RSSI - *Received Signal Strength Indication*) para permitir que um classificador, como o kNN (*k-Nearest Neighbor*), estime a posição dos nós. Tais soluções têm sido consideradas ultimamente devido a dois motivos principais: (1) disponibilidade das informações de potência do sinal sem necessidade de equipamentos extras; e (2) facilidade em tratar a grande variação e imprevisibilidade do RSSI em ambientes internos.

Nos sistemas baseados em treinamento, é comum que o dispositivo móvel envie alguns pacotes com uma certa potência de transmissão e estes serão recebidos por diversos roteadores com potências de recepção diferentes dependendo do posicionamento deles. Tais informações de potência de recepção serão utilizadas para determinar a posição do nó móvel através do classificador.

Neste trabalho, vamos além e experimentamos tal técnica através da variação da potência de transmissão dos pacotes enviados pelos nós móveis. Desta forma, na nossa solução, chamada SPoT (Sistema de Posicionamento com variação da Potência de Transmissão), ao invés de enviarmos diversos pacotes com a mesma potência de transmissão, enviamos diversos pacotes cada um com uma potência de transmissão diferente. O objetivo dessa variação é que o comportamento da queda dos sinais possa servir como uma característica extra para o classificador usado, como no nosso caso, o kNN (abordagem similar a Bahl & Padmanabhan [2000]), resultando em erros menores de localização.

Uma das áreas que tem atraído bastante interesse nos últimos anos, por estar vinculada ao aumento da capacidade dos processadores existentes no mercado, é a de aplicativos que consideram o contexto em que estão inseridos. Aplicativos orientados a contexto podem escolher a forma e o momento de se comunicar com o usuário, fornecendo informações relevantes e úteis, em função da situação em que o dispositivo e o usuário se encontram, das ações do usuário e de sua história pregressa. Tais aplicativos geralmente possuem mecanismos de inferência sobre os tipos de atividade e os objetivos que o usuário busca alcançar. Quando um aplicativo orientado a contexto é executado em um dispositivo móvel, uma informação que pode ser importante para esse processo é a localização deste dispositivo no ambiente em que ele se encontra.

¹Ekahau, Inc. Ekahau Positioning Engine 2.0. <http://www.ekahau.com/>

1.1 Motivação

Redes sem fio estão se tornando hoje cada vez mais populares, particularmente aquelas baseados na IEEE 802.11 (WiFi) [Crow et al., 1997]. Elas estão espalhadas em vários ambientes, desde praças públicas até em ambientes fechados, como shoppings. Junto a isso tivemos um grande desenvolvimento na área de dispositivos móveis de tal forma que hoje em dia uma grande quantidade de pessoas dispões de dispositivos moveis com acesso a redes do tipo WiFi. Uma funcionalidade que pode ser importante é determinar a localização de um dispositivo em qualquer ponto, especialmente em um ambiente fechado(*indoor*). A noção de posição permite acessar locais específicos e é crucial em várias aplicações de computação ubíqua, que vão desde conteúdo dependente do contexto passando por monitoramento de pessoas [Kolodziej & Hjelm, 2006], [Samama, 2008]. Existem inúmeras aplicações que necessitam da localização, principalmente em ambientes *indoor* onde o desafio é maior devido a fenômenos como obstrução e reflexão de sinal, então pesquisas sobre localização em ambientes *indoor* se fazem necessárias devido à demanda existente por esse serviço .

Há, atualmente, uma grande quantidade de sistemas de localização, principalmente voltados para ambientes *indoor*, que utilizam a infraestrutura de uma rede WiFi. O desafio é ser capaz de fornecer a localização com qualidade nesse tipo de ambiente, aproveitando-se de infraestrutura mínima ou da infraestrutura já existente. Um conjunto promissor de tecnologias a fornecer estas informações são o padrão WiFi e a Força do Sinal Recebido (RSSI), com base em técnicas de localização *indoor* [Bahl & Padmanabhan, 2000].

Um candidato natural a solução para sistemas de localização seria o Sistema de Posicionamento Global (GPS). Ele abrange a maioria da superfície da Terra e seus *chipsets* estão se tornando cada vez mais baratos, tornando-o viável para que sejam integrados em muitos dispositivos móveis, o que o torna um bom candidato a solução para o problema de localização. No entanto, GPS não é confiável quando se trata de ambientes internos (*indoor*) ou urbanos, por causa da obstrução do seu sinal por edifícios altos e outras construções [Ni et al., 2004].

Em ambientes ao ar livre essas soluções baseadas em *Global Navigation Satellite Systems* (GNSS), como o GPS ou mais recentemente o Galileo, são satisfatórios na maioria das aplicações. Porém, essa tecnologia não tem um bom comportamento em alguns tipos de ambientes como, por exemplo, no interior de edifícios. Técnicas alternativas têm que ser empregadas nesses casos e uma solução que tem sido muito utilizada é o uso de infraestrutura de redes WiFi. Assim, muitas metodologias que usam essa infraestrutura disponível em redes WiFi têm sido propostas.

O uso de sistemas baseados na tecnologia WiFi se deve principalmente a grande disponibilidade de infraestrutura, o que faz com que sistemas baseados nessa tecnologia possam, teoricamente, ser implementados em vários ambientes sem a necessidade de um grande investimento em infraestrutura.

O uso de força de sinal tem a vantagem de não necessitar de *hardware* extra, pois essa informação é disponibilizada pelo padrão WiFi. Porém a informação da potência de sinal recebida não tem um comportamento muito previsível, tendo vários fatores que influenciam sua variação que vão desde de o *layout* do ambiente até a sua temperatura como observado em Bahl & Padmanabhan [2000]. Como o RSSI naturalmente tem uma variação, são necessárias técnicas para se tratar e estimar a localização, usando como informação principal o RSSI. Muitas dessas técnicas são abordagens probabilísticas para geolocalização como em Bahl & Padmanabhan [2000] e Smailagic & Kogan [2002].

Recentemente, técnicas de aprendizagem de máquina com informação de RSSI têm sido utilizadas devido a duas razões principais [Boukerche et al., 2008] [Lee & Chen, 2007] : (1) a disponibilidade de potência do sinal sem a necessidade de equipamento adicional, e (2) a facilidade desses algoritmos em tratar a grande variação e imprevisibilidade do RSSI em ambientes internos.

1.2 Definição do Problema

O problema que pretendemos resolver com esse trabalho é o de localizar dispositivos móveis em ambientes fechados utilizando informações não muito confiáveis (potência de sinal recebido (RSSI)) utilizando-se da infraestrutura de uma rede WiFi.

1.3 Objetivos Gerais e Específicos

O principal objetivo desse trabalho é desenvolver uma nova abordagem de sistemas de localização para ambientes *indoor*, utilizando de uma nova informação a ser considerada que é a variação do RSSI da comunicação em diferentes potências de transmissão. Diferente dos sistemas tradicionais baseados em RSSI que usam a média do RSSI nos seus cálculos nossa abordagem pretende usar a variação da potência gerando novas informações (o RSSI da comunicação em varias potências) para fazer uma estimativa melhor com essa informação extra.

Os objetivos específicos são:

- Desenvolver um sistema de localização para dispositivos móveis que funcione bem em ambientes *indoor* usando como informação o RSSI.

- Demonstrar a eficácia de um método de localização em Redes Sem Fio baseado na variação da potencia de transmissão e do RSSI.
- Demonstrar a eficácia de um algoritmo de localização baseado em variação de RSSI e Mapas de RSSI (*fingerprinting*) usando variação de potência de transmissão para ambientes internos.

1.4 Estrutura

O presente documento está organizado em 6 capítulos onde, além deste capítulo introdutório, é possível identificar mais 5 capítulos. A primeira parte abrange os Capítulos 2, 3 , que resume toda a investigação efetuada relativa as técnicas e tecnologias envolvidas na localização em ambientes fechados. Estes capítulos servem de base à segunda parte da proposta, uma vez que ajudam à compreensão das problemáticas envolvidas nesta área. A segunda parte deste documento descrito nos capitulos 4 e 5 apresentam a nossa proposta e a forma como pretendemos executar nosso trabalho assim como experimentos e métodos de análise que pretendemos usar para validar nossa solução além de um capitulo de conclusões e trabalhos futuros.

Capítulo 2

Localização em ambientes internos (*indoor*)

Quando se pensa em localização para dispositivos moveis um candidato natural a solução seria o Sistema de Posicionamento Global (GPS) [Hightower & Borriello, 2001].

Em ambientes ao ar livre essas soluções baseadas em *Global Navigation Satellite Systems* (GNSS), como o GPS ou mais recentemente o Galileo, são satisfatórios na maioria das aplicações [Gu et al., 2009]. No entanto, o GPS não é confiável quando se trata de ambientes internos (*indoor*) ou urbanos, por causa da obstrução do seu sinal por edifícios altos e outras construções [Kaspar, 2005].

Com o intuito de resolver esse problema da localização em ambientes internos foram pesquisadas diversas tecnologias que podem e são utilizadas em sistemas de localização para ambientes internos, que passam por tecnologias que vão desde baseadas em infraestrutura de telefonia móvel passando por infravermelho e ultrassom [Gu et al., 2009].

Para definirmos um sistema de localização precisamos definir qual ou quais as informações que serão utilizadas para se fazer a estimativa da localização, qual vai ser o método de tratar esses dados, como eles serão agrupados e tratados ou seja precisamos de uma informação de entrada e de um algoritmo para tratá-los.

Uma das alternativas que tem se concretizado é através da exploração dos sinais das redes WiFi [Chintalapudi et al., 2010]. Junto com o padrão WiFi, um conjunto promissor de tecnologias a fornecer estas informações são a Força do Sinal Recebido (RSSI) [Lee & Chen, 2007], e técnicas de localização baseadas em mapas de RSSI (*fingerprinting*) [Kaemarungsi & Krishnamurthy, 2012] [Wassi et al., 2005].

2.1 Tipos de Localização

Aplicações diferentes podem requerer tipos diferentes de localização. Elas podem ser divididas em física e simbólica ou também em absoluta ou relativa [Hightower & Borriello, 2001].

A localização física é expressada na forma de coordenadas que identificam um ponto em um 2-D/3-D em um mapa. Os mais utilizados são o DMS (*degree/minutes/seconds*) e o *Universal Transverse Mercator* (UTM) [Liu et al., 2007].

A localização simbólica fornece uma informação menos precisa mais abstrata baseada em um ponto de referencia, por exemplo na cozinha, próximo a uma caixa postal, em um trem que chegando [Hightower & Borriello, 2001].

Normalmente é possível mapear um sistema de localização física em simbólica usando uma base de dados que mapeia as posições físicas em posições simbólicas conhecidas [de Pinho, 2003].

A informação de localização ainda pode ser classificada como absoluta ou relativa. Em localização absoluta o sistema de referencia é o mesmo para todas as unidades, como no GPS em que todos os dispositivos são localizados com base em atitude, longitude e altitude [Hightower & Borriello, 2001].

Em sistemas que fornecem a posição relativa, cada objeto possui seus pontos de referencia que são locais. Por exemplo um sistema de segurança para caminhões que usa a distancia relativa do caminhão para outros veículos na estrada [Kaspar, 2005].

Pode-se obter uma estimativa da posição absoluta se a localização absoluta dos pontos de referencia for conhecida [de Pinho, 2003], assim como um sistema de localização absoluta pode fornecer uma localização relativa bastando conhecer a localização dos pontos de referencia.

2.2 Tecnologias utilizadas em localização para ambientes internos

A localização em ambientes fechados é uma área que tem atraído o foco de pesquisa a algum tempo, devido a sua necessidade a muitos tipos de aplicações [Martin et al., 2010]. Existem diversas alternativas estudadas e diversas tecnologias que já foram empregadas em sistemas de localização para ambientes internos, que passam por tecnologias que vão desde baseadas em infraestrutura de telefonia móvel passando por WiFi, infravermelho e ultrassom. Nesta seção pretendemos apresentar algumas tecnologias que são utilizadas para este fim.

2.2.1 Localização em Redes WiFi

WiFi (*Wireless Fidelity*) é o nome dado a redes e dispositivos que implementam a especificação IEEE 802.11 para redes sem fio.

Uma rede WiFi estruturada é composta por dispositivos que se comunicam por radiofrequência com um ou mais Pontos de Acesso (PA) [Tanenbaum, 2002].

Pontos de acesso são entidades que fornecem acesso a rede cabeada para dispositivos da rede sem fio por meio de sinais de radiofrequência [IEEE, 2012], servindo de ponte entre a rede sem fio e a cabeada.

O uso de sistemas baseados na tecnologia WiFi se deve principalmente a grande disponibilidade de infraestrutura, o que faz com que teoricamente possam ser implementados em vários ambientes sem a necessidade de um grande investimento em infraestrutura [Chintalapudi et al., 2010].

Um dos principais motivos para o uso de redes WiFi para localização de dispositivos é justamente a ideia de se aproveitar essa infraestrutura que já existe disponível [Gu et al., 2009], dessa forma minimizando ou, se possível, eliminando a necessidade de instalações de novos aparelhos ou mesmo de alterações nos aparelhos existentes, para isso costuma-se utilizar como informação para o cálculo a potência do sinal recebido, também conhecido como RSSI (*Received Signal Strength Indication*) devido a essa ser uma informação disponibilizada pelo padrão WiFi. Existem outras técnicas como *Time of Arrival* (ToA) baseada no tempo de chegada do sinal ou pela diferença dos tempos de chegada *Time Differences of Arrival* (TDoA) podemos ainda utilizar o ângulo de chegada (*Angle of Arrival* - AoA) [Seco et al., 2009].

2.2.1.1 RSSI

O RSSI é uma informação que os *drivers* da rede WiFi sempre fornecem, por ser uma informação útil para a escolha de associação entre possíveis redes disponíveis [Moura, 2007].

O uso de força de sinal tem a vantagem de não necessitar de *hardware* extra, pois essa informação é disponibilizada pelo padrão WiFi, porém ela não tem um comportamento muito previsível, tendo vários fatores que influenciam sua variação que vão desde o *layout* do ambiente até a sua temperatura como observado em Bahl & Padmanabhan [2000]. Como o RSSI naturalmente tem uma variação, para ele ser melhor utilizado como informação principal, são necessárias técnicas para se tratar e estimar a localização. Muitas dessas técnicas usam abordagens probabilísticas como em Bahl & Padmanabhan [2000] e Smailagic & Kogan [2002] para geolocalização.




Figura 2.1. Localização por Tempo de Chegada

2.2.1.2 Tempo de chegada (ToA - *Time of Arrival*)

A técnica ToA se baseia na ideia de que distância entre o alvo móvel para a unidade de medição é diretamente proporcional ao tempo de propagação [Liu et al., 2007].

A fim de permitir o posicionamento de 2-D, as medições devem ser feitas com respeito a sinais de pelo menos três pontos de referência, como mostrado na Figura 2.1 .

Para os sistemas baseados em ToA, o tempo de propagação de sentido único é medido, e a distância entre a unidade de medição e transmissor de sinal é calculado. Em geral, os resultados diretos ToA têm dois problemas. Em primeiro lugar, todos os transmissores e os receptores do sistema tem que ser precisamente sincronizados o que necessita de hardware específico [Fink et al., 2010]. Em segundo lugar, todos os contadores precisam ser rotulados para cada sinal de transmissão, a fim de medir as unidades e discernir a distância que o sinal viajou [Liu et al., 2007]. ToA pode ser medida utilizando-se diferentes técnicas de sinalização, tais como *direct sequence spread-*

spectrum (DSSS) Peterson et al. [1998], Li et al. [2000] ou *Ultrawide Band* (UWB) Fontana & Gunderson [2002].

2.2.1.3 Diferença entre os tempos de chegada (TDoA - Time Difference of Arrival)

A técnica TDoA funciona medindo o tempo exato de chegada de um sinal transmitido em três ou mais locais separados. Como as ondas de rádio viajam a uma velocidade conhecida (à velocidade da luz), por meio do cálculo da diferença dos tempos de chegada de pares de receptores, é possível calcular as hipérboles em que o dispositivo de transmissão está situado [Assad, 2007].

Esta técnica pode funcionar com qualquer dispositivo de transmissão e só requer modificações nos receptores [Malekitabar et al., 2005].

A ideia da TDoA é determinar a posição relativa do emissor móvel ao examinar a diferença de tempo em que o sinal chega a múltiplas unidades, em vez de o tempo de chegada absoluta como no ToA.

Para cada medição TDoA, o transmissor deve situar-se em uma hiperboloide com uma diferença de alcance constante entre as duas unidades de medição. A equação da hiperboloide é dada pela equação (2.1)

$$R_{i,j} = (x_i - x)^2 + (y_i - y)^2 + (z_i - z)^2 - (x_j - x)^2 + (y_j - y)^2 + (z_j - z)^2 \quad (2.1)$$

onde (x_i, y_i, z_i) e (x_j, y_j, z_j) representam os receptores fixos i e j , e (x, y, z) , representam as coordenadas do alvo [Drane et al., 1998]. Exceto as soluções exatas para a equação TDoA hiperbólica mostrada em (2.1) por meio de regressão não linear, a solução mais fácil é para a linearização das equações através do uso de uma série de Taylor e criar um algoritmo iterativo [Torrieri, 1984].

É ainda necessária a sincronização temporal entre os vários pontos de acesso, o que torna este método dependente de hardware e como tal uma solução mais dispendiosa [Fink et al., 2010]. Outra desvantagem dessa técnica se deve a em ambientes internos termos muitos pontos de acesso e dispositivos sem fios existentes, os sinais são refletidos nos obstáculos existentes como paredes, mobílias e até mesmo pessoas [Osório, 2011].

2.2.1.4 Angulo de Chegada (AoA - Angle of Arrival)

Em AoA, a localização do alvo desejada pode ser encontrada pela intersecção de vários pares de linhas em ângulo, cada um formado pelo raio circular a partir de uma estação

de base ou uma estação móvel para o alvo [Liu et al., 2007]. Como mostrado na Figura 2.2, os métodos AoA podem usar pelo menos dois pontos de referência conhecidos (A, B), e dois ângulos medidos θ_1 , θ_2 para localizar em 2-D o ponto P . Localização AoA pode ser feita tanto com antenas direcionais ou com *arrays* de antenas [Liu et al., 2007]. As vantagens de AoA são que uma estimativa da posição pode ser determinada com apenas três unidades de medição de posicionamento 3-D ou duas unidades de medição de 2-D, e não necessita de sincronização entre as unidades de medição além de não ser necessária nenhum tipo de sincronização para que ele funcione.




Figura 2.2. Localização por Ângulo de Chegada

Por outro lado a necessidade de hardware específico [Rodrigues, 2011], que geralmente, tem custo elevado [Röhrig & Müller, 2009] e a queda na qualidade da localização quando o alvo está muito distante dos receptores [Liu et al., 2007] são desvantagens dessa abordagem. Algumas literaturas também chamam AoA como direção de chegada (DoA).

2.2.2 RFID

Uma rede RFID (*Radiofrequency Identification*) é composta essencialmente por três elementos principais [Bouet & dos Santos, 2008]: etiqueta que geralmente contém um número de identificação e está acoplada aos objetos ou pessoas que se pretende identificar, um leitor que detecta as etiquetas realizando determinadas operações sobre as mesmas e os servidores responsáveis pelo armazenamento e visualização de informação [Hahanov et al., 2007]. Tipicamente uma etiqueta RFID pode ser dividida em dois grupos distintos: etiquetas RFID passivas e ativas [Want, 2006].

A tecnologia RFID baseia em dois componentes principais um leitor (*reader*) e uma etiqueta que se comunicam através de sinais rádio para efetuar troca de informação, seu funcionamento diferente de outras tecnologias não requer qualquer tipo de contato sendo uma opção simples a captura de dados [Osório, 2011]. As etiquetas pode ser usadas em um objeto ou pessoa para fins de identificação e localização [Bouet & dos Santos, 2008].

Nos últimos anos, a tecnologia de identificação por frequência de rádio saiu da obscuridade para se tornar importante em aplicações que ajudam a acelerar a manipulação de mercadorias e materiais fabricados. RFID permite a identificação a distância, ao contrário de tecnologias anteriores como a de código de barras, ele faz isso sem a necessidade de uma linha de visão [Want, 2006].

Diferente das tecnologias WiFi onde as comunicação é iniciada ou finalizada deliberadamente pelos utilizadores, nos sistemas RFID a comunicação se estabelece automaticamente, iniciadas pelos leitores ou pelas etiquetas (no caso de etiquetas ativas) se estiverem ao alcance, essa característica levanta algumas questões ao nível da privacidade [Osório, 2011].

No entanto, o método de alimentação das etiquetas varia. Uma etiqueta ativa tem uma bateria interna ou esta ligada a alguma outra fonte de energia e tem também seu circuito de comunicação de radio frequência [Want, 2006]. Uma etiqueta ativa também podem ter funcionalidades adicionais, tais como a memória, e um sensor, ou um módulo de criptografia. Por outro lado, uma etiqueta passiva não tem nenhuma fonte de energia interna. Geralmente ela repassa o sinal recebido do leitor. Etiquetas passivas têm um tamanho menor e são mais baratas do que os etiquetas ativas, mas tem funcionalidades muito limitadas. Recentemente foram desenvolvidas etiquetas chamadas semipassivas. Nestas etiquetas a comunicação com os leitores é como nas etiquetas passivas, mas incorporaram uma bateria interna que alimenta constantemente o seu circuito interno [Bouet & dos Santos, 2008].

2.2.3 Infra-vermelho

As ondas de infravermelho são muito utilizadas na comunicação de curto alcance . É comum termos dispositivos de controle remoto utilizados nos aparelhos de televisão e videocassetes que empregam a comunicação por infravermelho. Eles são relativamente direcionais, econômicos e fáceis de montar mas, têm uma desvantagem importante, não atravessam objetos sólidos .Isso pode ser visto como uma qualidade já que um sistema infravermelho instalado em um ambiente fechado não interfere em um sistema semelhante instalado nas salas ou nos prédios adjacentes [Tanenbaum, 2002]. Outra vantagem do uso de emissores e detectores de infravermelho e que eles são pequenos e baratos, porém conseguem operar a um alcance de até 6 metros [Kaspar, 2005]. Suas desvantagens baseia-se nas limitações da tecnologia que tem um alcance curto [Gu et al., 2009], além de necessitar de de linha de visada para funcionar e ainda poder sofrer interferência de de fontes de luz muito intensas [Casas et al., 2007].

Por serem direcionais e fáceis de serem bloqueados faz com que alternativas como baseadas em radio se tornem mais atraentes [Tseng et al., 2001].

2.2.4 Proximidade

A técnica da célula mais próxima é um dos sistemas mais simples de localização, não utiliza, diretamente distâncias ou ângulos. Ela pode ser aplicada em praticamente qualquer rede com células como base, tal como GSM ou UMTS. Ela também pode ser usada em WLAN, onde é possível encontrar o ponto de acesso mais próximo de um cliente móvel. Esta técnica não tenta saber exatamente a localização do cliente e, portanto, não fornece alta precisão como outras técnicas tentam oferecer [Claro, 2006].

Sua principal vantagem é a simplicidade e a desvantagem e que são necessários muitos sensores espalhados no ambiente para termos estimativas melhores da posição do objeto o que aumenta muito o custo de implantação [Rodrigues, 2011], porém se tivermos aplicação com requisitos baixos pode ser uma boa solução.

Normalmente fornecer localização simbólica, depende de uma densa rede de antenas, cada um com uma posição conhecida. Quando um alvo móvel é detectado por uma única antena considera-se que o objeto está “perto dela”. Quando mais do que uma antena detectar o alvo , ele é considerado perto da que receber sinal mais forte dela. Este método é relativamente simples de implementar [Liu et al., 2007].

2.2.5 Bluetooth

Em 1994, a Ericsson se interessou em conectar seus telefones móveis a outros dispositivos sem o uso de fios. Junto com outras quatro empresas (IBM, Intel, Nokia e Toshiba), ela formou um SIG (*Special Interest Group*) com o objetivo de desenvolver um padrão sem fio para interconectar dispositivos e prover comunicação entre eles e acessórios, utilizando rádios sem fios de curto alcance, baixa potência e baixo custo [Tanenbaum, 2002]. Uma das suas principais características é o alcance de comunicação limitado (10 metros para dispositivos classe 1) e baixo consumo de energia, além do curto alcance outra desvantagem e a quantidade de dispositivos suportados que é por vezes muito limitado [Rodrigues, 2011]. A popularidade atual do protocolo sem fio Bluetooth se deve ao seu curto alcance, baixo consumo de energia e facilidade de integração o que o torna um forte candidato a ser incorporado a dispositivos móveis [Hossain & Soh, 2007].

2.2.6 Zigbee

O padrão 802.15.4 estabelece a camada Física (PHY) e a camada de acesso ao meio (MAC). Já o padrão ZigBee define a camada de rede. Desta forma, ZigBee é desenvolvido sobre a pilha do 802.15.4 e usa a camada física desta pilha [Rodrigues, 2011].

O IEEE 802.15.4 é uma norma sem fios proposta e mantida pela Zigbee Alliance IEEE [2005] [Yang & Yang, 2009] com vista a satisfazer a necessidade de criação de redes de baixo custo e baixo consumo. É um padrão para redes de área pessoal (PANs), que visa a baixa taxa de dados, curto alcance de comunicação e baixo custo. Adicionalmente, as aplicações devem ter baixa taxa de transferência de dados [Rodrigues, 2011]. Ele pode prover uma rede *mesh* que oferece alta confiabilidade, e também torna mais fácil a implantação [Larranaga et al., 2010]. Permite uma comunicação bidirecional, o que é indicado para utilização em sistemas de localização interior [Osório, 2011]. Permite uma boa comunicação *peer-to-peer*, com a rede suportando três tipos de topologias: estrela, árvore e malha cada uma com até 65535 nós, com uma estrutura auto-organizável e auto-reparável, que permite o *relay* de dados através de *multi-hop* entre quaisquer dois nós [Osório, 2011].

2.2.7 Conclusão

Das tecnologias avaliadas nesse trabalho, a tecnologia nos parece ser a melhor solução para nosso problema é o uso de infraestrutura WiFi visto que com ela não necessitamos de *hardware* específico como nas outras abordagens. A tecnologia de Bluetooth apesar

de ser uma tecnologia muito difundida assim como WiFi tem limitações de alcance e quantidade de dispositivos o que pode causar problemas ambientes com muitos dispositivos ou mesmo pelo alcance limitado. O padrão Zigbee é mais usado em redes de sensores, não existem muitas redes Zibee disponíveis o que nos faz descartá-lo também. A técnica de célula mais próxima funciona melhor para localização simbólica (que não é nosso caso) e por isso tem uma precisão baixa. Outras tecnologias como infravermelho e ultrassônicos necessitam de hardware específico o que pode encarecer muito a solução. O uso de RFID é uma boa solução por ser barata e compatível com o padrão WiFi, porém como pretendemos utilizar apenas infraestrutura existente vamos descartá-la também visto que são necessárias as etiquetas RFID no ambiente de localização. Mais próximo do que desejamos estão as técnicas que usam TDoA, ToA que usam tempo de chegada de sinais WiFi, o grande problema dessas técnicas é a necessidade de sincronização o que na prática se torna inviável em redes WiFi comuns. Temos ainda as técnicas baseadas em AoA que há a necessidade de antenas direcionais o que nem sempre é possível de se ter em redes comuns. Então em nosso trabalho usaremos infraestrutura WiFi usando como informação o RSSI visto que redes WiFi são bem populares e o RSSI é de fácil obtenção nesse tipo de rede .

2.3 Algoritmos utilizados em localização para ambientes internos

Existem muitas técnicas que podem ser empregadas quando se procura estimar localização utilizando sinais de radiofrequência. Cada uma delas tem suas vantagens e desvantagens, adequando-se melhor a cada tipo de contexto. Para que se possa definir qual técnica melhor se adequa ao contexto de localização WiFi é importante conhecê-las.

2.3.1 Técnicas Geométricas

Técnicas geométricas se baseiam em algoritmos iterativos que calculam a posição do nó pela formulação e resolução de um conjunto de equações não-lineares [Zheng & Jamalipour, 2009].

A mais utilizada é a triangulação que utiliza as propriedades geométricas de triângulos para estimar a localização do alvo. Ela tem duas derivações: lateração e angulação [Liu et al., 2007].

Lateração calcula a posição de um objeto através da medição das suas distân-

cias de vários pontos de referência. Esse método é baseado no cálculo de um sistema linear em que para se localizar um dispositivo são necessários 3 nós vizinhos (que tenham comunicação com o dispositivo a ser localizado) que saibam a sua localização e que o dispositivo a ser localizado possa calcular a distância entre ele e esses 3 outros dispositivos (por exemplo usando o RSSI). Se conseguirmos quatro vizinhos com informação de localização podemos ampliar essa localização para 3D. A desvantagem deste algoritmo é que é necessário muito recurso para implementá-lo [Langendoen & Reijers, 2005]. Um dos principais problemas dessas técnicas é se obter uma boa estimativa da distância entre os dispositivos muitas técnicas já foram propostas para fazer essa estimativa [Rodrigues, 2011].

Esses algoritmos são baseados na perda de sinal causada pelo caminho que o sinal percorre. Com base no estudo da variação do RSSI é feita uma função que estima essa perda utilizando um conjunto de valores coletados em vários pontos conhecidos, com essa informação podemos determinar essa relação entre os valores de RSSI e a distância a partir do nó de transmissão para o nó receptor. Um modelo usando equações de regressão deste relacionamento pode ser construído e usado para estimar as distâncias com base em valores RSSI.

Outra abordagem que também é utilizada é o uso de modelos estatísticos para se tentar mapear o comportamento do ambiente.

Angulação tem um funcionamento similar a lateração, porém localiza um objeto utilizando ângulos em relação a vários pontos de referência [Al Nuaimi & Kamel, 2011]. A informação que é normalmente utilizada é a do ângulo de chegada (AoA). A localização do alvo pretendido pode ser encontrada pela intersecção de vários pares de linhas, cada um em ângulo formado pelo raio circular a partir de uma estação de base ou um *beacon* para o alvo [Liu et al., 2007].

2.3.2 Técnicas *Fingerprinting* (Mapas de RSSI)

Muitos sistemas de localização são concebidos com base nas técnicas *fingerprinting*, visto que ela apresenta bons resultados além de ser relativamente fácil e barato de implementar em comparação com outras técnicas [Abdat et al., 2010].

Técnicas de impressão digital WiFi constroem modelos por divisão do espaço em células como uma grade [Haeberlen et al., 2004] ou como nós conectados por um grafo [Kolodziej & Hjelm, 2006]. Probabilidades de medição são então construídas para cada localidade. A probabilidade final de uma localização, dada uma medida, representa no máximo, a probabilidade de apenas um ponto específico (o centro da célula da grade ou o nó do grafo).

Um sistema de posicionamento baseado em impressões digitais tem duas fases: a fase de treinamento (*off-line*) e fase de determinação da posição (*on-line*) [Kaemarungsi & Krishnamurthy, 2004].

Durante a *off-line*, os valores de intensidade de sinal de múltiplos pontos de acesso são medidos e recolhidos, para em seguida formarem o mapa de rádio. Um mapa de rádio é uma tabela que com a intensidade de sinal de todos os pontos de acesso visíveis mapeada para uma localização fixa.

Na fase *on-line* para determinar a posição de um dispositivo sem fio o sistema tenta corresponder o sinal de um dispositivo com as entradas da tabela. A correspondência mais próxima da entrada é a provável posição do dispositivo [Abdat et al., 2010]. Normalmente essa correspondência é calculada por meio de técnicas de reconhecimento de padrões : k-vizinhos mais próximos (kNN), redes neurais (RNA), métodos probabilísticos, e máquinas de vetores de suporte (SVM) [Abdat et al., 2010].

A grande desvantagem é que a construção do mapa de RSSI, quando os padrões são obtidos experimentalmente que é o método mais usado, é muito custoso pois é necessário uma base de dados sobre toda a extensão em se necessita fazer a localização [Claro, 2006].

2.3.3 Redes Neurais Artificiais (RNA)

Redes Neurais Artificiais (RNA) tem a vantagem de conseguir bons resultados mesmo com dados muito ruidosos, como e o caso do RSSI, e são amplamente utilizados quando a correlação entre os valores de entrada e saída de um sistema não é clara ou está sujeita a interferências [Altini et al., 2010].

As redes neurais mais conhecidas e empregadas na literatura, são redes *Perceptron* de Múltiplas Camadas (MLP - “*Multi-Layer Perceptron*”) [Zhang, 2000]. Esta classe de redes é bastante usada na prática em problemas de classificação, além de possuir grande habilidade de aprender através de treinamento, e ter um alto poder computacional [HAYKIN, 2001].

Uma rede neural consiste de um conjunto de neurônios artificiais interconectados, onde as saídas de alguns neurônios alimentam as entradas de outros [Saha et al., 2003] (ver Figura 2.3).

A grande dificuldade em se usar uma MLP é a sua configuração. Há dois problemas maiores em se criar uma MLP, aprender a estrutura da rede e aprender os pesos das conexões. Existe um algoritmo relativamente simples para determinar os pesos de uma rede fixa, este algoritmo é chamado de retropropagação . No entanto, embora existam muitos algoritmos que tentam identificar a estrutura de rede, este aspecto do problema




Figura 2.3. Rede Neural Artificial (RNA).

é normalmente resolvido empiricamente combinado com uma dose de conhecimento especializado do problema [Witten et al., 2011].

A vantagem das RNAs reside nos seguintes aspectos teóricos. Em primeiro lugar, as RNAs são orientadas a dados e autoadaptativas já que tem o poder de se ajustar aos dados sem qualquer especificação explícita. Em segundo lugar, elas podem em teoria aproximar qualquer função com precisão arbitrária [Zhang, 2000].

2.3.4 Maquinas de Vetores de Suporte (SVM - *Support Vector Machine*)

Um método de classificação que normalmente apresenta alto grau de desempenho é *Support Vector Machines* (SVMs) [Kotsiantis, 2007]. Desenvolvido por Vapnik [1995], é um dos mais populares algoritmos de classificação. Este método transforma os vetores de características em um espaço de dimensões maiores, em que as classes podem ser separadas linearmente por hiperplanos [Marsland, 2011]. É uma ferramenta para análise estatística e aprendizagem de máquina, e ele executa muito bem em muitas aplicações de classificação e de regressão [Liu et al., 2007].

Ele é considerado uma mistura de modelagem linear e aprendizagem baseada em instâncias. Usa um pequeno número de casos críticos de fronteira chamados vetores de suporte de cada classe e construir uma função discriminante linear que tenta separar as classes o mais melhor possível [Witten et al., 2011].

A complexidade do modelo gerado pelo SVM não é afetada pelo número de características encontradas nos dados de treinamento (o número de vetores de suporte selecionados pelo algoritmo de aprendizagem SVM é geralmente pequena). Por esta razão, SVMs são bem adequados para lidar com as tarefas em que o número de características é grande em relação ao número de ocorrências [Kotsiantis, 2007].

Suas desvantagens se devem a complexidade computacional necessaria para se encontrar os vetores de suporte que são únicos, para uma mesma base e mesmo problema, além de problemas com superajuste (*overfitting*) [Witten et al., 2011].

Um dos problemas do SVM é a escolha adequada da parametrização, visto que isso pode ser determinante na obtenção de bons resultados. É comum o uso da técnica chamada de validação cruzada sobre o conjunto de treinamento para encontrar a melhor configuração. Por esta razão, a limitação de SVMs é a baixa velocidade do treinamento. Selecionar as definições do kernel podem ser considerados de uma forma semelhante ao escolher o número de nós escondidos numa rede neural [Kotsiantis, 2007].

2.3.5 k-Nearest Neighbor (kNN)

Como visto anteriormente as técnicas baseadas em *fingerprinting* necessitam de um banco de dados sobre o ambiente e de um algoritmo que faça o tratamento dessa informação, um algoritmo que tem sido muito utilizado na literatura e que obteve bons resultados foi o kNN Bahl & Padmanabhan [2000] Wassi et al. [2005].

Na área de reconhecimento de padrões, o algoritmo kNN é considerado um algoritmo de aprendizado supervisionado e foi introduzido por Cover & Hart [1967]. A ideia geral desse algoritmo “consiste em encontrar os k exemplos rotulados mais próximos do exemplo não classificado e, com base no rótulo desses exemplos mais próximos, é tomada a decisão relativa à classe do exemplo não rotulado” [Ferrero, 2009].

Um objeto é classificado pelo voto da maioria de seus vizinhos, a quantidade de vizinhos é a variável K (K é um inteiro positivo, tipicamente pequeno). Se $K = 1$, então o objeto é simplesmente atribuído à classe do seu vizinho mais próximo.

Embora a aprendizagem baseada em instâncias seja simples e eficaz, muitas vezes ela é lenta, a maneira mais óbvia de encontrar qual o membro do conjunto de treinamento é o mais próximo a uma instância de teste desconhecida é calcular a distância de cada membro do conjunto de treinamento e escolher o menor. Em outras palavras, o

tempo que leva para fazer uma única previsão é proporcional ao número de instâncias de treino. O processamento de um conjunto de teste inteiro levaria o tempo proporcional ao produto do número de casos teste pela número de amostras a serem classificadas [Witten et al., 2011].

Os algoritmos da família kNN requerem pouco esforço durante a etapa de treinamento. Em contrapartida, o custo computacional para rotular um novo exemplo é relativamente alto, pois, no pior dos casos, esse exemplo deverá ser comparado com todos os exemplos contidos no conjunto de exemplos de treinamento [Witten et al., 2011].

2.3.6 Conclusão

Dos métodos de localização vistos nesta seção os que melhor se encaixam para serem utilizados em nosso trabalho são o uso de mapas de RSSI e o uso do algoritmo de classificação kNN. Técnicas que utilizam modelos do ambiente não obtiveram resultados tão bons quanto as técnicas que utilizam mapas de radio devido principalmente as características do sinal WiFi que sofre com problemas como o *multipath*, o que torna a criação de funções que transformam RSSI em distancia suscetíveis a erros muito elevados. O kNN foi escolhido por ser um algoritmo que trata bem dados muito ruidosos como é o caso do RSSI, por que diferente do SVM e das RNA's quem tentam criar uma superfície de separação (que às vezes não existe) ele rotula pelas amostras mais parecidas.

2.4 Características do Problema de Localização em Redes WiFi

Desde o surgimento da tecnologia WiFi tem se tentado desenvolver vários métodos para determinar a localização de dispositivos, porém muitas dessas soluções se tornavam impraticáveis devido a serem focadas em características muito específicas dos ambientes para qual eram desenvolvidas perdendo assim muito da sua capacidade de resolver o problema de forma satisfatória em ambientes diferentes dos testados.

A grande vantagem do uso de redes WiFi em localização se deve a sua grande disponibilidade em prédios, campi universitários e outros ambientes internos o que reduz o custo de implantação de uma solução desse tipo, uma vez que não é necessário estruturar o ambiente, como ocorre nas soluções baseadas em infravermelho e ultrassom [Rodrigues, 2011].

Em ambientes externos o problema da localização é resolvido de forma razoável usando GPS (*Global Positioning System*). Porém ele não tem um bom funcionamento em ambientes fechados, devido a falta de um caminho de transmissão com linha de visão entre receptores e satélites [Gu et al., 2009].

Muitas abordagens de localização anteriores utilizam Força de Sinal Recebido (RSSI) como uma métrica para determinações da localização e com elas pode-se obter facilmente impressões digitais da maioria dos equipamentos de rede sem fios com WiFi ou mesmo ZigBee [Yang et al., 2012].

Não é fácil de modelar a propagação de rádio em ambientes fechados por causa do fenômeno de *multipath*, baixa probabilidade para disponibilidade de caminhos com *line-of-sight* (LOS), características específicas do local, objetos se movendo, e numerosas superfícies refletindo o sinal [Liu et al., 2007].

Não há nenhum modelo que resolva por completo o problema de *multi-path* em ambientes fechados [Pahlavan et al., 2002]. As melhores abordagens incluem triangulação tradicional, algoritmos que usam análise de cena ou proximidade. Para diferentes tipos de aplicações ou serviços, estes três algoritmos têm vantagens e desvantagens. Consequentemente, usando mais de um tipo de algoritmo ao mesmo tempo poderíamos ter um melhor desempenho [Liu et al., 2007].

2.4.1 Interferência de Propagação de caminho Múltiplo *multipath*

Interferência causada por sinais refletindo em muros e outros obstáculos e a chegada ao receptor em diferentes tempos é chamada de interferência *multipath* [Kaspar, 2005].

Podem existir vários obstáculos como paredes, equipamentos, pessoas, influenciando a propagação de ondas eletromagnéticas o que pode criar os efeitos de *multipath*. Interferências e fontes de ruído de outras redes sem fio podem também degradar a estimativa de localização [Gu et al., 2009]. A geometria de edifício, a mobilidade das pessoas e as condições atmosféricas podem resultar em *multi-path* e efeitos ambientais [Ladd et al., 2004].

Essas características podem resultar em efeitos como múltiplas versões do sinal transmitido que chegam à antena receptora, deslocados em relação um ao outro na orientação temporal e espacial. Essa variação dos componentes de um mesmo sinal faz com que o receptor receba o sinal com flutuações na intensidade de sinal, induzindo assim a atenuação em pequena escala, a distorção do sinal, ou ambos [Rappaport, 2002].

As várias formas de *multipath* são ilustradas na Figura 2.4.




Figura 2.4. Formas de *multipath*

Capítulo 3

Trabalhos relacionados

A necessidade de compreender como a localização de dispositivos móveis é feita em redes WiFi, tornou imprescindível a realização de um estudo de alguns sistemas de localização em redes WiFi, analisando as várias arquiteturas usadas, bem como os métodos de localização que certos investigadores usaram para conseguirem chegar a bons resultados. Nesse capítulo pretendemos apresentar algumas das principais soluções de localização em ambientes *indoor* dando ênfase as soluções que se usam das tecnologias que utilizaremos, que são infraestrutura de redes WiFi e a Força de Sinal Recebido (RSSI) aliadas a técnicas de Mapas de RSSI (*fingerprinting*).

3.1 Sistemas de localização usando diversas Tecnologias

O sistema Active Badge de Want et al. [1992], é um exemplo de sistema baseado em proximidade. Foi desenvolvido na Olivetti Research Laboratory, agora AT&T Cambridge, consiste em um sistema de proximidade celular que utiliza a tecnologia de infravermelho (IR). Emissores e detectores de infravermelhos são pequenos e baratos e são capazes de funcionar dentro de uma faixa de 6 metros. No Active Badge, cada crachá emite códigos únicos a cada 15 segundos, que são captados por uma rede de sensores colocados em todo o ambiente interno. Uma estação central coleta os avistamentos dos crachás pela rede de sensores, processa os dados e torna disponível para clientes a localização [Want & Schilit, 2001].

Posteriormente, os laboratórios da AT&T desenvolveram um sistema mais preciso que o Active Badge, chamado Active Bat Ward et al. [1997], que utiliza a técnica de triangulação através de sinais ultrassônicos emitidos pelo Active Bat Tag, um pequeno

dispositivo acoplado a unidade móvel. Cada sensor de teto (controlador local) está conectado em rede serial cabeada ao controlador central. Para obter a localização de uma unidade móvel, o controlador central envia ao mesmo tempo um pacote de requisição via onda de radio, e um sinal de sincronização aos sensores de teto através da rede serial. Cada sensor de teto mede o intervalo de tempo do sincronismo até o pulso ultrassônico recebido e calcula a distancia até o equipamento Bat. O controlador central recebe as distancias calculadas pelos receptores locais e faz o calculo da triangulação, obtendo a localização da unidade móvel. Portanto, para fornecer a localização, o sistema utiliza a técnica de lateração, calculando a distancia entre os pontos de referência através da abordagem *time-of-flight*. Isso possibilita um sistema muito preciso, estima-se que esse sistema tenha uma precisão de 9 cm em 95% das medições.

Os sistemas baseados em bluetooth se diferenciam dos baseados em WiFi pelo alcance dos dispositivos e o número de dispositivos disponíveis no ambiente. Em geral, quando utiliza-se Wi-Fi, o número de dispositivos é maior porque eles também funcionam como infraestrutura de rede [Rodrigues, 2011].

Em Rodriguez et al. [2005] temos um sistema que usa Bluetooth baseado em mapas de assinaturas e trilateração. Nesse trabalho temos uma abordagem centralizada pois o dispositivo móvel envia o RSSI coletado de vários *beacons* Bluetooth para um servidor que estima a localização e também discreta visto que são utilizadas células de 1,2 metros. Os testes foram realizados em um laboratório de 10x5 metros e apresentam erros de menos de 1,2 metros quando se usa três pontos de acesso.

Em Diaz et al. [2010] o usuário é passivo, são os APs Bluetooth distribuídos no ambiente que coletam RSSI dos usuários e a sua localização é simbólica (sala) e baseada em modelos de propagação do sinal de radio (são utilizados três modelos Linear, Exponencial e ITU), com erros variando entre 2,33 e 8,39 metros, dependendo do modelo e de parâmetros utilizados.

Mapas de RSSI combinados com algoritmos probabilísticos em redes Zigbee são utilizados em Yao et al. [2007] para realizar localização, os erros médios foram de 0,5 metro em 70% dos casos.

Em Lau et al. [2009] temos um sistema baseado mapas de assinaturas em redes Zigbee . A interferência causada pelas redes WiFi é considerada na avaliação como maior fonte de erros nesse caso, segundo os autores, há uma alta perda de pacotes enviados pelos *beacons* devido a interferência.

3.2 Sistemas de Localização Usando RSSI e Fingerprinting

Nos algoritmos baseados em mapas de RSSI a localização de um nó de destino corresponde pontos no mapa RSSI, que registra os valores de RSSI obtidos por *beacon* em diferentes pontos. Um método típico utilizando o mapeamento de RSSI é o vizinho mais próximo (kNN), algoritmo de treinamento baseado em Bahl & Padmanabhan [2000].

No algoritmo kNN, um conjunto de dados de nós *beacon* em pontos diferentes é usada para treinar o algoritmo e para obter o mapa de assinatura RSSI.

Dados os dados de RSSI de um dispositivo a ser localizado, o sistema procura no mapa gerado pelos k registros, que sejam mais próximos (que tenham o RSSI mais parecido), de modo a determinar a localização que é definida usando o cálculo da distância Euclidiana.

A metodologia padrão envolve um treinamento *off-line* e uma fase de calibração, em que bases de dados de intensidade do sinal são construídas. Estas bases de dados são usadas para triangularização e localização do alvo durante a fase *on-line* [Jan & Lee, 2003].

Existem vários sistemas de localização *indoor* que usam kNN: RADAR Bahl & Padmanabhan [2000], Landmarc Ni et al. [2004], Ekahau que é um sistema de localização em tempo real (RTLS) para ambientes *indoor* Ekahau [2009].

Um dos primeiros sistemas de localização usando RSSI foi proposto por Bahl & Padmanabhan [2000] seu mecanismo de localização é baseado na técnica *nearest neighbor(s)* que nada mais é do que o kNN. Neste trabalho são propostas duas abordagens para determinar a localização.

Na primeira abordagem é feita uma análise empírica da potência de sinal na fase *offline*. Observando os resultados nessa fase offline eles perceberam que vários fatores influenciam na precisão da localização como por exemplo orientação do usuário, número de vizinhos mais próximos utilizados, o número de pontos de amostragem e número de amostras na fase de tempo real.

A segunda é um modelo de propagação do sinal. Fator de atenuação de parede (WAF) que é baseado no fator atenuação de piso (FAF) foi usado, em vez do modelo Rayleigh de queda e do modelo de distribuição Rician, que são utilizadas em situações ao ar livre. WAF leva em consideração o número de paredes (obstáculos). A precisão do sistema de radar é de cerca de 2,94 metros em 50% dos casos.

Em seu trabalho seguinte Bahl et al. [2000], RADAR foi melhorado por um al-

goritmo *Viterbi-like*. Seu resultado é que o 50 percentil do sistema RADAR é de cerca de 2,37-2,65 metros e seu 90 percentil é de cerca de 5,93-5,97 metros.

Um sistema de localização semelhante ao RADAR é o Landmarc Ni et al. [2004], porém ele tem a vantagem de não necessitar de uma fase offline. Isto se deve porque que o Landmarc utiliza etiquetas RFID ativas como referencia. A ideia principal do Landmarc é adotar as coordenadas das k mais próximas etiquetas de referência para calcular os valores das coordenadas dos alvos, onde as k t etiquetas de referencia são selecionadas de acordo com a distância euclidiana com base na potência de sinal. Obteve erros menores que 1 metro em aproximadamente 50% dos casos.

O sistema Horus de Youssef et al. [2003], Youssef & Agrawala [2004] propõe uma técnica de agrupamento conjunta para a estimativa de localização que usa um método probabilístico próprio. Nesse sistema cada possível coordenada em que o candidato possa estar é considerada uma classe ou categoria. A fim de minimizar o erro de distância, a localização L_i é escolhida quando a sua probabilidade é maior. Os resultados dos experimentos mostram que esta técnica pode alcançar uma precisão de mais de 90% para 2,1 metros de erro.

Em Roos et al. [2002] foi desenvolvido um algoritmo baseado em uma grade *bayesiana* sobre uma região pequena de um prédio de escritórios, obtendo a localização e rastreamento com erro de menos 2,76 metros 90% das vezes.

Em Battiti et al. [2002], é proposto um método de determinação de localização por meio de redes neurais baseadas em classificadores. Eles adotaram uma arquitetura *multilayer perceptron* (MLP) e um método de treinamento passo-secante (OSS). Eles escolheram a arquitetura de três camadas com três unidades de entrada, oito unidades da camada escondida e duas saídas, uma vez que esta arquitetura teve o menor erro de treinamento e é menos sensível ao "overfitting". Eles relataram que apenas cinco amostras de intensidade do sinal para os diferentes locais são suficientes para obter um erro médio de 3 metros. Aumentar o número de exemplos de treinamento ajuda a diminuir o erro médio para 1,5 metros.

Os autores em Saha et al. [2003] compararam um classificador de redes neurais com o classificador de vizinho mais próximo (kNN) e métodos probabilísticos. Conseguiram com redes neurais erro de 1 metro com probabilidade de 72%.

Em Ladd et al. [2002], Ladd et al. [2004] é proposto um algoritmo baseado em um grades *bayesianas* de localização. Na primeira etapa do algoritmo um *host* usa um modelo probabilístico para calcular a probabilidade da sua localização para diferentes locais, com base no RSSI de nove APs. A segunda etapa explora a velocidade máxima limitada de usuários dos aparelhos móveis para refinar os resultados (da primeira etapa) e rejeitar soluções com mudança significativa na localização do aparelho. Dependendo

se o segundo passo é usado ou não, 83% e 77% do tempo os *hosts* conseguem estimar a localização com 1,5 metros de erro.

Haeberlen et al. [2004] apresentou um método prático *bayesiano* robusto para a localização topológica sobre uma rede 802.11 implantada dentro de um prédio de escritórios. Eles demonstraram que o uso de um modelo topológico pode reduzir drasticamente o tempo necessário para treinar o localizador, enquanto a precisão resultante é ainda suficiente para muitas aplicações. Conseguiram um erro menor que 3 metros em 90%.

Siddiqi et al. [2003] utiliza o método de Monte Carlo, e obteve resultado com erros nas de no eixo x em torno de 2 metros e em y em torno de 4 metros.

Kontkanen et al. [2004] introduziu um sistema com um assistente de rastreamento. Este sistema foi usado para desenvolver o sistema Ekahau, um sistema de localização comercial que combina redes *bayesianas*, complexidade estocástica e aprendizagem competitiva, para fornecer localização através de um servidor central.

Em Xiang et al. [2004], propôs um modelo baseado na distribuição de propagação sinal e um algoritmo de rastreamento e posicionamento, no qual uma máquina de estado é usada para trocar entre rastreamento e não rastreamento para conseguir mais precisão. Conseguiu alcançar uma precisão de 2 metros com probabilidade de 90% para determinação da posição estática. Para um dispositivo em movimento 1,5 metros precisão com probabilidade de 90%.

Em Hamza & Nerguizian [2009], é demonstrado que técnicas de localização *fingerprinting* têm desempenho melhor do que as tradicionais baseadas em triangularização, porque o fenômeno de *multipath* é uma informação importante. No entanto, isso geralmente é verdade em condições estáticas, porém as técnicas de *fingerprinting* sofrem degradações na precisão da localização em ambientes dinâmicos, onde as propriedades podem mudar com o tempo. Isto é devido ao fato de que a técnica precisa de uma coleção nova de dados quando uma mudança de estado do canal ocorre. Este trabalho propõe um método permitindo a localização precisa de um usuário de um aparelho móvel em tempos variados quando é difícil ou impossível para coletar medições. O sistema tem a capacidade de gerar, a partir de um banco de dados de referência, um novo banco de dados correspondente a um estado novo do canal. Isto é feito usando medições de pontos de referência algumas em conjunto com uma técnica de modelo de árvore de mineração de dados. A técnica utiliza uma análise de regressão para saber a relação temporal entre os valores preditivos da força de sinal recebida dos dispositivos móveis e os pontos de referência, a fim de gerar um novo banco de dados em um estado de tempo diferente. Depois de gerar várias bases de dados correspondentes aos estados de tempo diversos uma rede neural artificial é usada para a estimativa de localização.

Resultados mostram uma melhora em comparação a uma técnica estática de aproximadamente 7% e 11% a 3 metros em 2D e 3D respectivamente em ambientes dinâmicos. No ambiente 2D (5º andar do edifício considerado), utilizando 140 padrões não treinados, os resultados mostraram valores de precisão de localização 68,33% e 61,38% para uma precisão de 3 metros de canais estáticos e dinâmicos, respectivamente. Como para o ambiente 3D (5º e 6º andares do edifício considerado), utilizando 290 padrões não treinados, os resultados mostraram um valor de precisão de localização 2D de 57,06% para uma precisão de 3 metros; uma degradação de 11% em relação ao caso estático. Além disso, um valor de precisão de 98,3% foi obtida para a direção de 'z' (estimativa dos níveis dos pisos).

Em Fang & Lin [2010] é feito um estudo que se centra na localização usando Força de Sinal Recebido (RSSI) em ambientes densos com *multipath indoor*. Uma abordagem com um sistema dinâmico é proposto no módulo localização por impressão digital, onde o local é estimado a partir do estado em vez do RSSI diretamente. O estado é reconstruído a partir de uma sequência temporal de amostras RSSI, incorporando uma estrutura adequada de memória baseado na teoria de embarcados de Taken. Então, uma melhor estimativa de localização é dada devido o impacto da variação temporal do *multipath* ser considerada. Para as comparações foi definido o erro como sendo a distância euclidiana entre a saída do sistema e a posição real do dispositivo cliente. Quatro medidas de erro foram relatadas incluindo desvio padrão (erro padrão), erro médio, mediana e CEP 67% (probabilidade de erro circular). O CEP é definido como o raio do círculo que tem seu centro no local verdadeira e contém as estimativas de localização com uma probabilidade [Weiss, 2003]. O método proposto foi comparado com outros 2 métodos baseados em estados como filtros de Kalman e HMM (*Hidden Markov Model*) [Franklin et al., 1997], [Grewal & Andrews, 2001]. Ele obteve uma acurácia superior a dos outros métodos em todas as medidas avaliadas.

Em Fang & Wang [2011] é proposto uma técnica denominada *Dynamic Hybrid Projection* (DHP), em que uma projeção é determinada dinamicamente explorando as vantagens complementares de duas técnicas a *Principal Component Analysis* (PCA) e a *Multiple Discriminant Analysis* (MDA), evitando suas propriedades desfavoráveis. Ele teve duas grandes contribuições primeiro ele cria uma técnica híbrida que incorpora o poder discriminativo em PCA e compensa os problemas do MDA em uma estrutura unificada. Segundo, DHP ajusta dinamicamente um mecanismo híbrido com informações extras, sobre a região de entrada *on-line*. Ou seja, a projeção proposta é dependente da entrada, enquanto as projeções tradicionais são fixas após o treinamento. O algoritmo proposto foi testado em um ambiente real. Os resultados experimentais demonstram que DHP supera esquemas de projeção estática, reduzindo a 50th e 67th percentil dos

erros de localização para 24,73% -30% e 18,18% -19,51% , respectivamente, comparado com PCA e MDA.

Capítulo 4

SPoT: Sistema de Posicionamento com Variação da Potência de Transmissão

Neste capítulo explicaremos melhor o funcionamento do SPoT (Sistema de Posicionamento com variação da Potência de Transmissão), sistema de localização proposto neste trabalho.

Como visto em muitos trabalhos na literatura as técnicas que se utilizam de mapas de RSSI ou técnicas *fingerprinting* tem tido um bons resultados em ambientes *indoor*. Como visto anteriormente também esses sistemas baseados em treinamento, como o nosso sistema, tem duas fases distintas uma primeira fase chamada de fase *offline* ou fase de treinamento e uma segunda fase chamada de fase *online* (fase de localização).

4.1 Arquitetura do Sistema de Localização

O funcionamento e as fases do nosso algoritmo podem ser vistos na arquitetura geral do SPoT que é ilustrada na Figura 4.1.

Nessa arquitetura, na fase de treinamento, será criado um mapa de RSSI que servirá de base para o treinamento do kNN. Esse mapa é gerado levando um dispositivo móvel (usamos um *notebook*) para uma localização conhecida da região de interesse e fazendo com que ele envie pacotes de dados em diferentes potências de transmissão. Os pacotes serão recebidos pelos roteadores (3 ou mais) que guardarão os dados de RSSI em uma base de dados junto a posição conhecida do dispositivo. Tal procedimento deverá ser realizado em cada uma das células que se deseja obter a localização dos

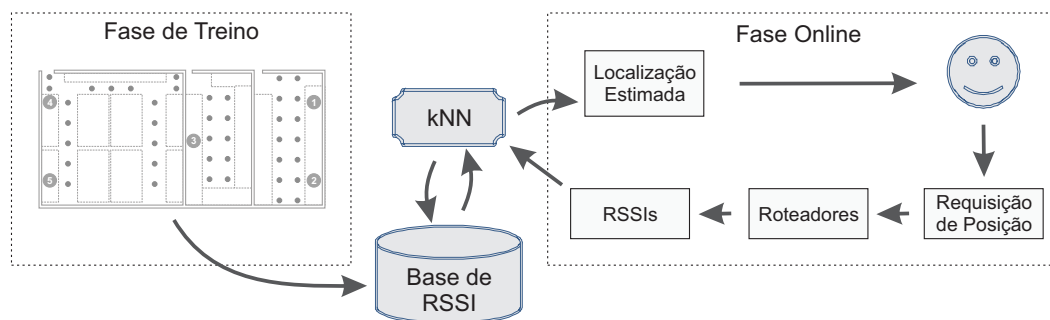


Figura 4.1. Arquitetura do Sistema de Localização.

dispositivos. Quanto maior o treinamento, maior será a precisão do sistema (mais informação).

Na segunda fase (*online*), um dispositivo móvel (que passar pela rede) poderá requisitar a sua localização enviando dois ou mais pacotes em potências diferentes e com base nos RSSIs observados nos roteadores, o classificador kNN estimará a localização (célula) do dispositivo.

4.2 Localização usando Variação da Potência de Transmissão

Conforme mencionado, nos sistemas encontrados na literatura, são utilizados como informação de entrada os RSSIs recebidos nos diferentes roteadores WiFi ou mesmo uma média de uma janela de RSSIs recebidos (diversos pacotes enviados pelo nó móvel).

Em nosso trabalho propomos o uso de informação que não é usada em outras abordagens para assim o classificador (kNN) pode obter uma melhor qualidade na inferência da localização do dispositivo móvel. Entretanto, precisamos de novas características (informações) que possam ser de fácil obtenção em uma infraestrutura WiFi. Desta forma, a ideia da nossa proposta é utilizar a comunicação entre dispositivo e roteadores com diferentes potências de transmissão, visto que isso é um recurso disponível na maioria dos *drivers* de dispositivos WiFi comercializados atualmente [Moura, 2007].

Tendo essas informações extras, passamos para a segunda fase que é a escolha de um algoritmo para o tratamento dos dados. Como optamos por resolver nosso problema de maneira discreta (conforme explicado mais adiante), escolhemos um algoritmo de classificação que é simples mas que obteve bons resultados em outros trabalhos como em Bahl & Padmanabhan [2000] e Ni et al. [2004] por ter características que auxiliam

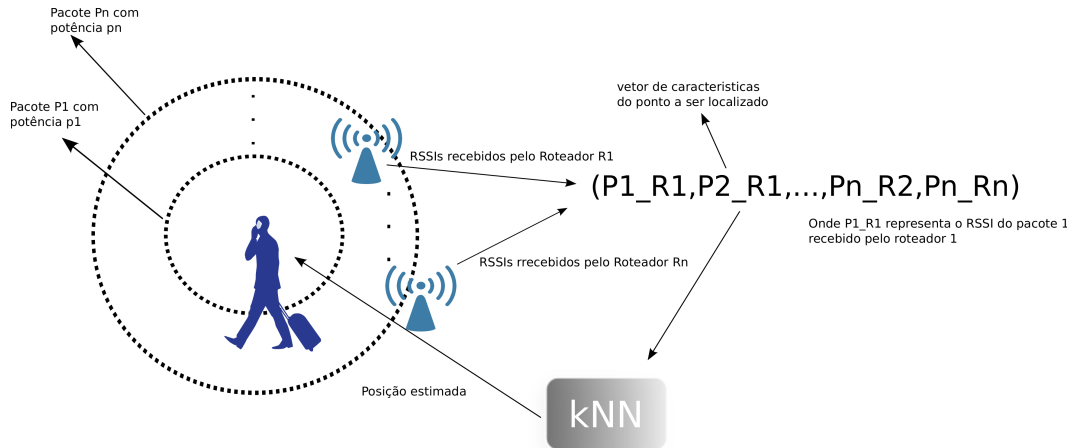


Figura 4.2. Funcionamento do SPoT.

no tratamento de informações muito ruidosas como o RSSI. Tal classificador é o kNN (*k-Nearest Neighbor*).

O funcionamento do nosso algoritmo pode ser sintetizado como visto na Figura 4.2.

Em nossa modelagem usando o kNN, cada indivíduo (amostra coletada ou ponto a ser localizado) é representado em um plano cartesiano onde suas coordenadas correspondem aos valores das suas características, assim uma amostra de um ponto X é representada por um ponto (x_1, x_2, \dots, x_n) onde n é o número de características da amostra, cada coordenada (x_1, x_2, \dots, x_n) corresponde a um valor do RSSI em uma determinada potência de transmissão recebido por um determinado roteador como pode ser visto ainda na Figura 4.2.

Um exemplo do uso do kNN para localização usando apenas dois RSSIs pode ser observado na Figura 4.3.

Ao utilizar o kNN, é necessário ajustar os parâmetros do classificador que, neste caso são o valor de k (que representa o número de vizinhos que serão considerados no cálculo) e como será feito o cálculo da distancia entre 2 pontos.

Para definirmos a melhor configuração para nosso classificador, foram feitos experimentos preliminares para ajustar esses parâmetros, dessa forma obtemos bases preliminares para testar entre varias configurações qual a melhor considerando como métrica a taxa de acerto.

Porém a escolha desses parâmetros pode ser tediosa, e selecionar os atributos manualmente pode apresentar problemas, pois conhecimento prévio sobre os dados de treino não podem ser usados ao selecionar os parâmetros; caso contrário, a estimativa de desempenho será influenciada pela base não pelo problema [Witten et al., 2011].

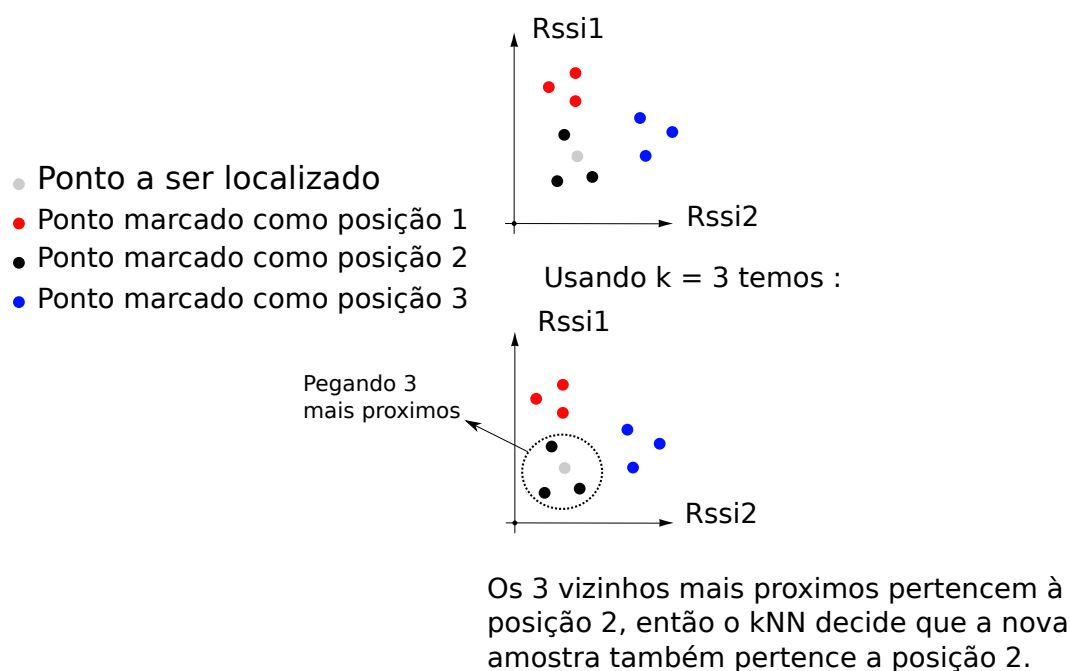


Figura 4.3. Exemplo do kNN em duas dimensões.

Nós usamos o *metalearner* do Weka o *CVPParameterSelection*, ele procura pelos melhores parâmetros otimizando com base na técnica conhecida como validação cruzada dos dados de treinamento. Por padrão é utilizada uma validação cruzada em 10 *folds* [Witten et al., 2011]. Foram testados k 1 a 50 devido a ideia de que o kNN não é sensível à escolha exata de k mas sim a magnitude do k [Wettschereck et al., 1997], mas nós não podemos usar k muito grande devido aos dados de teste terem apenas 134 exemplos.

Usando essa técnica de seleção de parâmetros, foi possível decidir no kNN com k igual a 5 e usando o calculo de distancia “Manhattan”, uma vez que essa configuração se mostrou melhor nos testes preliminares.

Como nas outras abordagens baseadas em treinamento, nossa proposta de localização é discreta. Isso significa que ela não diz exatamente qual a localização do nó, mas sim em que “célula” ele se encontra. Desta forma, o kNN foi treinado com amostras rotuladas pelo centro de uma área de $1m^2$ (célula), onde foram feitas as coletas que construíram a sua base de treinamento. Dessa forma, se o classificador acerta a célula em que o dispositivo se encontra é considerado que ele acertou a posição do dispositivo. Tal asserção é bem razoável visto que o erro máximo do centro para qualquer parte da célula será de 0,7m como pode ser visto na Figura 4.4.




Figura 4.4. Erro na Celula.



Figura 4.5. Cisco/Linksys WRT610N.

4.3 Configuração e Experimentos

A avaliação do SPoT foi realizada através de experimentos práticos em um ambiente interno (*indoor*). Em nossos experimentos, utilizamos roteadores sem fio Cisco/Linksys WRT610N (Figura 4.5) com o *firmware* DD-Wrt ¹ e um software simples desenvolvido para a captura dos pacotes e obtenção dos RSSIs (baseado na *libpcap*).

Para isso, foram escolhidas 3 salas do Instituto de Computação duas com área de $3.5 \times 7 \text{ m}^2$ e uma de $7 \times 7 \text{ m}^2$, essas salas são laboratórios de grupos de pesquisa tendo

¹www.dd-wrt.com/




Figura 4.6. Coleta de Informações.

então muitos obstáculos como bancadas, armários, cadeiras e etc.

A implementação do kNN usada foi a da ferramenta *Waikato Environment for Knowledge Analysis*² (WEKA) que é uma coleção de algoritmos de aprendizado de máquina para tarefas de mineração de dados. Escolhemos essa ferramenta por ser simples (apesar de possuir muitas funcionalidades) e ser disponibilizada gratuitamente, além de possuir muita documentação disponível.

4.3.1 Montando o Mapa de RSSI

Para a primeira fase do sistema (*offline*), foi necessário obter uma base de dados sobre a variação do RSSI para o treinamento do kNN.

Foram dispostos cinco roteadores que ficaram captando os pacotes que estavam sendo enviados a partir de um *notebook*, conforme pode ser visto na Figura 4.6. O *notebook* foi colocado em posições previamente definidas e conhecidas no *grid*, conforme mostra ainda na Figura 4.6.

Foram coletados 200 pacotes por posição alternando a potência de transmissão em 5 valores diferentes. Tais valores foram: 0, 5, 10, 15 e 20 dBm.

Os pacotes de treinamento foram captados pelos cinco roteadores e armazenados para a construção da base de dados, resultando em uma base contendo informações

² <http://www.cs.waikato.ac.nz/ml/weka/>

sobre as 41 posições do *grid*. Em seguida, tais informações da base foram utilizadas para o treinamento do kNN.

Capítulo 5

Avaliação de Performance

Neste capítulo discutiremos os resultados da nossa abordagem comparadas de varias formas com a abordagem Convencional e com variações suas, para termos uma melhor visão do seu funcionamento e particularidades.

Para fins de comparação, foi implementado um sistema de localização Convencional baseado em treinamento e usando o kNN. Conforme mencionado anteriormente, tal sistema é baseado na utilização de uma única potência de transmissão. Os experimentos dessas variações do sistema foram realizados ao mesmo tempo e com os mesmos equipamentos utilizados na nossa abordagem. Desta forma, será possível ver com melhor precisão a influência da utilização de diferentes potências de transmissão no erro de localização, uma vez que todo o restante do experimento se manteve igual nas duas abordagens.

A primeira abordagem chamada por nós de “Convencional” é similar a usada no RADAR em Bahl & Padmanabhan [2000], usa apenas um pacote com potência padrão. Ela compara a potência recebida, apenas uma, de cada roteador com a base do mapa e estima com qual mais se “parece”. Usando cinco roteadores uma amostra A seria representada como na formula (5.1)

$$A = \{R_1_RSSI, ..., R_N_RSSI\} \quad (5.1)$$

com R_N_RSSI (onde $N = \{1, ..., 5\}$) representando o RSSI de um pacote recebido pelo roteador N .

A abordagem Convencional com média é similar a Convencional com a diferença que usamos três pacotes com potência padrão (em nossa placa 20 dBm) e calculamos sua média. Testamos calculando a média simples entre 3 pacotes, essa média dos pacotes recebidos é comparada com as medias na base do mapa e assim estima-se com

qual mais ela se “parece”. Usando cinco roteadores uma amostra B seria representada como na formula (5.2)

$$B = \{R_1_Mean_RSSI, ..., R_5_Mean_RSSI\} \quad (5.2)$$

com $R_N_Mean_RSSI$ (onde $N = \{1, ..., 5\}$) representando a média de RSSIs de três pacotes recebidos pelo roteador N (enviados com a mesma potência de transmissão).

Na abordagem chamada de “SPoT 3P: 20 20 20 ” foram usadas três características como RSSIs de pacotes enviados na mesma potência (20 dBm) . Cada pacote foi considerado como uma característica (similar ao SPoT-3P). Assim em vez representarmos uma posição como um único atributo por roteador, como um valor de RSSI por roteador na abordagem “Convencional” ou a média de três RSSIs por roteador como na “Convencional/Média”, teremos um atributo de 15 dimensões (3 pacotes por roteador) sendo cada característica do atributo um RSSI. Assim uma amostra C pode ser representada como visto na formula (5.3)

$$C = \{R_1_RSSI_1, R_1_RSSI_2, R_1_RSSI_3, ..., R_5_RSSI_1, R_5_RSSI_2, R_5_RSSI_3\} \quad (5.3)$$

onde $R_N_RSSI_M$ (com $N = \{1, ..., 5\}$ e $M = \{1, 2, 3\}$) representa o RSSI do pacote de numero M (enviado com a potência de 20 dBm) recebido pelo roteador N .

Foram avaliadas também variações do SpOT. Coletamos amostras de treino e de teste com cinco potências de transmissão (0, 5, 10, 15 e 20 dBm). Variando entre 2, 3 e 4 quantidades de potências obtemos amostras D no formato descrito em (5.4).

$$D = \{R_1_RSSI_0, R_2_RSSI_0, R_3_RSSI_0, R_4_RSSI_0, R_5_RSSI_0, ..., \\ R_1_RSSI_{20}, R_2_RSSI_{20}, R_3_RSSI_{20}, R_4_RSSI_{20}, R_5_RSSI_{20}\} \quad (5.4)$$

com $R_N_RSSI_P$ (onde $N = \{1, ..., 5\}$ e $P = \{0, 5, 10, 15, 20\}$) representa o RSSI de um pacote enviado com a potência P recebido pelo roteador N .




Figura 5.1. Resultados obtidos usando cinco roteadores.

5.1 Análise dos Resultados usando Cinco Roteadores

Para analisarmos os resultados obtidos pelo SPoT, utilizamos como métrica o erro acumulado em metros (FDA - Função de Distribuição Acumulada). O erro de classificação para cada amostra, nas 41 células de 1m^2 , é calculado com base na posição real da coleta e na posição estimada pelo classificador.

No gráfico da Figura 5.1, podemos ver o comportamento do erro acumulado para 3 configurações diferentes do SPoT comparadas a 2 variações da abordagem Convencional. A curva “SPoT-5P” mostra o comportamento do erro de localização para o SPoT utilizando as 5 potências de transmissão estudadas, ou seja, o nó móvel enviou 5 pacotes com potências de transmissão diferentes (0, 5, 10, 15 e 20 dBm). Por usar mais características, esta curva foi a que obteve melhores resultados, confirmando as nossas suposições iniciais de que as diferentes potências poderiam ser usadas para melhorar a qualidade do classificação. Como se pode observar nessa curva, nosso sistema foi capaz de localizar os nós com um erro abaixo de 1m em mais de 95% dos casos.

Ainda na Figura 5.1, a curva “SPoT-3P: 5 10 15” mostra o comportamento do SPoT utilizando apenas três potências diferentes, ou seja, o nó móvel enviou três pa-

cotes com potências de transmissão diferentes (5, 10 e 15 dBm). Esta curva se mostrou um pouco inferior à primeira por utilizar menos informações. Entretanto, é fácil de se perceber que os resultados foram bastante próximos e que, assim como na primeira curva, ela ainda se destaca das demais, sendo uma solução aceitável para os casos em que se queira reduzir a quantidade de pacotes enviados pelo dispositivo móvel.

Para melhor entender os resultados obtidos, implementamos uma versão do SPoT que utiliza três pacotes (parecido com a variação anterior) mas que em vez de usar pacotes com potências diferentes, esta variação utilizou pacotes diferentes mas com a mesma potência de transmissão (20 dBm). Apesar de não ser o algoritmo proposto, essa variação serviu para diferenciar mais facilmente o que é ganho relativo à variação do sinal do que não é. Como pode ser observado na curva “SPoT-3P: 20 20 20”, esta variação ficou bem abaixo das outras duas, que utilizaram a variação da potência de transmissão. Este resultado mostra claramente que os ganhos obtidos pelo SPoT devem-se basicamente à mudança da potência de transmissão.

Finalmente, a curva “Convencional” ilustra o comportamento de um sistema de localização Convencional, através de um classificador kNN que utiliza os dados de RSSIs obtidos a partir de um único pacote sempre usando a mesma potência de transmissão. Já a curva “Convencional/Média” mostra novamente a abordagem Convencional mas com o envio de três pacotes (usando a mesma potência de transmissão) e tirando a média dos RSSIs destes três pacotes. Como pode se observar, as duas abordagens tradicionais obtiveram uma qualidade de localização bem inferior se comparado ao SPoT.

5.2 Análise dos Resultados usando Três e Quatro Roteadores

Na seção anterior, mostramos os resultados obtidos pelo SPoT utilizando os cinco roteadores disponíveis. Para entender um pouco mais do seu funcionamento e comportamento em diferentes cenários resolvemos experimentar a solução proposta utilizando apenas três roteadores, quantidade mínima necessária para obter uma solução única, e usando quatro roteadores pra termos uma ideia do impacto da quantidade de roteadores no resultado. Como haviam cinco roteadores disponíveis, foram realizados testes com as várias combinações de roteadores, 3 a 3, resultando em 10 possíveis combinações de roteadores e várias combinações de roteadores 4 a 4 (sendo 5 possíveis).

As combinações para cada quantidade de roteadores que podem ser vistas nos gráficos da Figuras 5.2 e 5.3.




Figura 5.2. Resultados obtidos usando três roteadores.

Novamente, podemos observar que o SPoT foi capaz de localizar os nós com erros bem abaixo dos obtidos pelas abordagens tradicionais. Comparando estes gráficos com os anteriores (Figura 5.1), é possível observar uma queda muito pequena na qualidade da localização, mostrando que nossa abordagem mantém uma qualidade aceitável mesmo com uma quantidade menor de roteadores e mostrando ainda que ao se aumentar a quantidade de roteadores, há um ganho muito pequeno na qualidade da localização, o que pode não compensar na maioria dos casos.

5.3 Análise dos Resultados usando diferentes combinações de Potências de Transmissão

Conforme mencionado anteriormente, e observado no gráfico da Figura 5.2, a utilização do SPoT com apenas três pacotes (com três potências diferentes), teve resultados próximos aos obtidos executando o SPoT com 5 pacotes e potências diferentes. Como tínhamos que escolher 3 potências de transmissão dentre as 5 disponíveis, resolvemos analisar o comportamento do erro de localização obtido por essas possíveis combinações. A ideia inicial era avaliar, por exemplo, se a utilização das potências maiores de transmissão seria mais vantajoso em relação às potências menores. Entretanto,




Figura 5.3. Resultados obtidos usando quatro roteadores.

o que foi observado e que está ilustrado no gráfico da Figura 5.4 é que basicamente não houve mudança no desempenho do sistema. Portanto, levando-se em consideração que os pacotes enviados com potências maiores alcançam distâncias maiores, o gráfico da Figura 5.4 indica que podemos utilizar as maiores potências disponíveis (10, 15 e 20 dBm, neste caso) sem se preocupar com uma degradação perceptível na precisão da localização.

Ainda nessa linha de combinações das potências, e procurando aumentar ainda mais os conhecimentos sobre o comportamento do sistema, resolvemos executar o SPoT fazendo o dispositivo móvel enviar apenas dois pacotes e também com 4 pacotes com potências de transmissão diferentes. Assim como no resultado anterior, diversas combinações surgem a partir das 5 potências disponíveis. Dentre as combinações disponíveis, escolhemos as quatro mais relevantes quando se envia dois pacotes e as três para com quatro pacotes e executamos o SPoT com elas. Os resultados obtidos são mostrados nos gráficos das Figuras 5.5 e 5.6. Novamente, como se pode observar, não houve diferenças significativas nos resultados. Entretanto, comparando estes gráficos com o anterior (que usa três potências), é possível perceber que houve uma queda na qualidade da localização quando se usa duas potências e um pequeno ganho quando se usa 4 potências. Daí, pode-se observar que o SPoT é bem dependente da quantidade de




Figura 5.4. Resultados obtidos variando as potências 3 a 3.

pacotes enviados em potências diferentes, motivo esse que nos levará a pesquisar ainda mais nossa solução com a utilização de ainda mais potências (trabalhos futuros).

5.4 Análise dos Resultados usando diferentes Quantidades de Potências de Transmissão

No gráfico da Figura 5.7, podemos observar o comparativo com várias quantidades de potência. Com o uso de apenas 2 potências, já é possível observar uma melhora considerável na qualidade de localização. Aumentando a quantidade de potências utilizadas para 3, 4 e 5 potências, é possível observar um ganho ainda maior na localização. Entretanto, é possível observar que o incremento de ganho de uma quantidade de potências para outra parece diminuir, concluindo-se que se faz necessário uma relação de compromisso entre o acerto do classificador e o custo em quantidade de pacotes enviados pelo dispositivo móvel, uma vez que mais potências/características significa o uso de mais pacotes.




Figura 5.5. Resultados obtidos variando potências 2 a 2.

5.5 Análise do Acerto por Posição

Nos gráficos das Figuras 5.8 e 5.9, podemos observar o comparativo da porcentagem de acertos (erro 0), nas várias posições definidas no espaço onde foram coletadas as amostras, para com isso termos uma visão da distribuição espacial do erro no nosso ambiente de localização.




Figura 5.6. Resultados obtidos variando as potências 4 a 4.




Figura 5.7. Resultados obtidos variando a quantidade de potências.

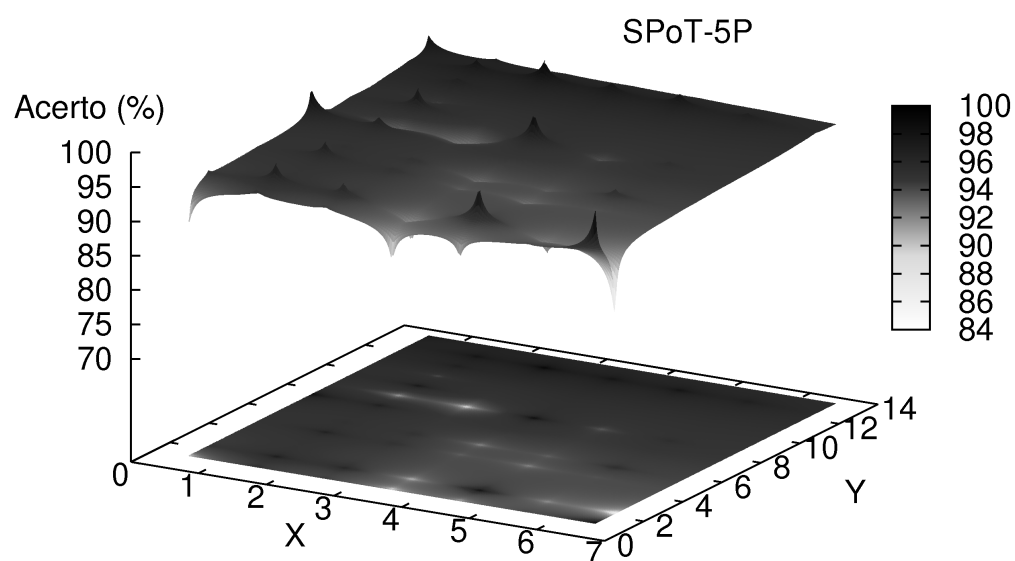


Figura 5.8. Distribuição do erro por Posição SPoT-5P.




Figura 5.9. Distribuição do erro por Posição na Abordagem Convencional.

Capítulo 6

Conclusões e Trabalhos Futuros

Com esse trabalho podemos observar que a área de localização em ambientes *indoor* é uma área muito abrangente e que apesar de já existirem muitos métodos já bem aceitos e estudados que existe muita coisa ser feita para obtermos melhores resultados. Em nosso trabalho foi proposto uma nova abordagem de localização para ambientes *indoor* diferente da abordagem tradicional baseada em RSSI, em que se usa a média do RSSI como a informação para a localização, nossa abordagem utiliza a variação de potencia de transmissão para assim obter mais características para um classificador kNN.

Dessa forma obtemos mais características que possam definir um determinado local, com o intuito de realizar uma melhor localização pelo fato de dispormos de mais informação.

O sistema proposto foi avaliado através de experimentos reais em um ambiente interno utilizando diversas combinações de (1) quantidade de roteadores, (2) quais roteadores, (3) quantidade de potências de transmissão, e (4) quais potências de transmissão, tudo isso comparado com a abordagem tradicionalmente utilizada em localização interna bem como com sua variante que usa a média do RSSI de vários pacotes.

Os resultados obtidos apontam fortes indícios de que essas características extras de diferentes potências são relevantes e melhoram a qualidade da localização obtendo-se erros de menos de 1 m em 96% dos casos em alguns cenários. Os resultados obtidos são bastante promissores, foram testadas varias configurações com até 5 potencias diferentes, porém observamos que com 3 potencias já temos um ganho bem significativo contra a abordagem tradicional que só utiliza uma potencia de transmissão.

Como trabalhos futuros, pretendemos experimentar o SPoT em ambientes maiores e com mais obstáculos, nesse trabalho ele foi testado em laboratórios da universidade a ideia seria testá-lo no instituto todo. Além disso, serão realizados experimentos com uma quantidade maior de pacotes com diferentes potências, para avaliar até quando

podemos aumentar a quantidade de pacotes e ainda obter resultados melhores. Outra parte importante a ser feita é a implementação de fato para dispositivos móveis visto que nesse trabalho utilizamos um notebook com *beacon* além da análise de outras possíveis informações para serem utilizadas como por exemplo frequência de transmissão e análise de interferência por canal.

Referências Bibliográficas

- Abdat, M.; Wan, T.-C. & Supramaniam, S. (2010). Survey on indoor wireless positioning techniques: Towards adaptive systems. Em *Distributed Framework and Applications (DFmA)*, 2010 International Conference on, pp. 1--5.
- Al Nuaimi, K. & Kamel, H. (2011). A survey of indoor positioning systems and algorithms. Em *Innovations in Information Technology (IIT)*, 2011 International Conference on, pp. 185--190.
- Altini, M.; Brunelli, D.; Farella, E. & Benini, L. (2010). Bluetooth indoor localization with multiple neural networks. Em *Wireless Pervasive Computing (ISWPC)*, 2010 5th IEEE International Symposium on, pp. 295--300.
- Assad, M. A. (2007). A real-time laboratory testbed for evaluating localization performance of wifi rfid technologies. Dissertação de mestrado, WORCESTER POLYTECHNIC INSTITUTE.
- Bahl, P.; ; Bahl, P.; Padmanabhan, V. N. & Balachandran, A. (2000). Enhancements to the radar user location and tracking system. Relatório técnico.
- Bahl, P. & Padmanabhan, V. (2000). Radar: an in-building rf-based user location and tracking system. Em *INFOCOM 2000. Nineteenth Annual Joint Conference of the IEEE Computer and Communications Societies. Proceedings. IEEE*, volume 2, pp. 775--784 vol.2.
- Battiti, R.; Nhat, T. L. & Villani, A. (2002). Location-aware computing: A neural network model for determining location in wireless lans. Relatório técnico, University of Trento.
- Bouet, M. & dos Santos, A. (2008). Rfid tags: Positioning principles and localization techniques. Em *Wireless Days, 2008. WD '08. 1st IFIP*, pp. 1--5.

- Boukerche, A.; Oliveira, H. A. B. F.; Nakamura, E. F. & Loureiro, A. A. F. (2008). Vehicular ad hoc networks: A new challenge for localization-based systems. *Comput. Commun.*, 31(12):2838--2849.
- Casas, R.; Cuartielles, D.; Marco, A.; Gracia, H. & Falco, J. (2007). Hidden issues in deploying an indoor location system. *Pervasive Computing, IEEE*, 6(2):62--69.
- Chintalapudi, K.; Padmanabha Iyer, A. & Padmanabhan, V. N. (2010). Indoor localization without the pain. Em *Proceedings of the sixteenth annual international conference on Mobile computing and networking*, MobiCom '10, pp. 173--184, New York, NY, USA. ACM.
- Claro, P. M. F. (2006). Sistema de posicionamento local baseado em rede wi-fi. Dissertação de mestrado, Departamento de Electrónica, Telecomunicações e Informática; Universidade de Aveiro.
- Cover, T. & Hart, P. (1967). Nearest neighbor pattern classification. *Information Theory, IEEE Transactions on*, 13(1):21--27.
- Crow, B.; Widjaja, I.; Kim, L. & Sakai, P. (1997). Ieee 802.11 wireless local area networks. *Communications Magazine, IEEE*, 35(9):116--126.
- de Pinho, L. M. A. (2003). Sistemas de localização dinâmica de serviços em ambientes de computação móvel. Dissertação de mestrado, Universidade de São Paulo. Instituto de Matemática e Estatística.
- Diaz, J.; de A Maues, R.; Soares, R.; Nakamura, E. & Figueiredo, C. (2010). Bluepass: An indoor bluetooth-based localization system for mobile applications. Em *Computers and Communications (ISCC), 2010 IEEE Symposium on*, pp. 778--783.
- Drane, C.; Macnaughtan, M. & Scott, C. (1998). Positioning gsm telephones. *Communications Magazine, IEEE*, 36(4):46--54, 59.
- Ekahau, I. (2009). The case for real time location systems.
- Fang, S. & Wang, C. (2011). A dynamic hybrid projection approach for improved wi-fi location fingerprinting. *IEEE Transactions on Vehicular Technology*, 60(3):1037--1044.
- Fang, S.-H. & Lin, T.-N. (2010). A dynamic system approach for radio location fingerprinting in wireless local area networks. *Trans. Comm.*, 58:1020--1025.

- Ferrero, C. A. (2009). Algoritmo knn para previsão de dados temporais: funções de previsão e critérios de seleção de vizinhos próximos aplicados a variáveis ambientais em limnologia. Dissertação de mestrado, Universidade de São Paulo.
- Fink, A.; Beikirch, H.; Voss, M. & Schroder, C. (2010). Rssi-based indoor positioning using diversity and inertial navigation. Em *Indoor Positioning and Indoor Navigation (IPIN), 2010 International Conference on*, pp. 1--7.
- Fontana, R. & Gunderson, S. (2002). Ultra-wideband precision asset location system. Em *Ultra Wideband Systems and Technologies, 2002. Digest of Papers. 2002 IEEE Conference on*, pp. 147--150.
- Franklin, G. F.; Powell, D. J. & Workman, M. L. (1997). *Digital Control of Dynamic Systems (3rd Edition)*. Prentice Hall.
- Grewal, M. S. & Andrews, A. P. (2001). Kalman filtering : Theory and practice using matlab california state university at fullerton. *Theory and Practice*, 5(5):634--6.
- Gu, Y.; Lo, A. & Niemegeers, I. (2009). A survey of indoor positioning systems for wireless personal networks. *Communications Surveys Tutorials, IEEE*, 11(1):13--32.
- Haeberlen, A.; Flannery, E.; Ladd, A. M.; Rudys, A.; Wallach, D. S. & Kavraki, L. E. (2004). Practical robust localization over large-scale 802.11 wireless networks. Em *Proceedings of the 10th annual international conference on Mobile computing and networking*, MobiCom '04, pp. 70--84, New York, NY, USA. ACM.
- Hahanov, V.; Filippenko, I. & Lavrova, L. (2007). Contemporary rfid systems and identification problems. Em *CAD Systems in Microelectronics, 2007. CADSM '07. 9th International Conference - The Experience of Designing and Applications of*, pp. 343--344.
- Hamza, L. & Nerguizian, C. (2009). Neural network and fingerprinting-based localization in dynamic channels. Em *Intelligent Signal Processing, 2009. WISP 2009. IEEE International Symposium on*, pp. 253--258.
- HAYKIN, S. (2001). *Redes Neurais - 2ed.* BOOKMAN COMPANHIA ED.
- Hightower, J. & Borriello, G. (2001). Location systems for ubiquitous computing. *Computer*, 34(8):57--66.
- Hossain, A. & Soh, W.-S. (2007). A comprehensive study of bluetooth signal parameters for localization. Em *Personal, Indoor and Mobile Radio Communications, 2007. PIMRC 2007. IEEE 18th International Symposium on*, pp. 1--5.

- IEEE (2005). Draft amendment to ieee standard for information technology-telecommunications and information exchange between systems-part 15.4:wireless medium access control (mac) and physical layer (phy) specifications for low-rate wireless personal area networks (lr-wpans): Amendment to add alternate phy (amendment of ieee std 802.15.4). *IEEE Std P802.15.4a/D5*, pp. --.
- IEEE (2012). Ieee standard for information technology-telecommunications and information exchange between systems local and metropolitan area networks-specific requirements part 11: Wireless lan medium access control (mac) and physical layer (phy) specifications. *IEEE Std 802.11-2012 (Revision of IEEE Std 802.11-2007)*, pp. 1--2793.
- Jan, R.-H. & Lee, Y. R. (2003). An indoor geolocation system for wireless lans. Em *32nd International Conference on Parallel Processing Workshops (ICPP 2003 Workshops)*, 6-9 October 2003, Kaohsiung, Taiwan, pp. 29--34. "IEEE Computer Society".
- Kaemarungsi, K. & Krishnamurthy, P. (2004). Properties of indoor received signal strength for wlan location fingerprinting. Em *Mobile and Ubiquitous Systems: Networking and Services, 2004. MOBIQUITOUS 2004. The First Annual International Conference on*, pp. 14--23.
- Kaemarungsi, K. & Krishnamurthy, P. (2012). Analysis of wlan's received signal strength indication for indoor location fingerprinting. *Pervasive Mob. Comput.*, 8(2):292--316.
- Kaspar, D. (2005). Application of directional antennas in rf-based indoor localization systems. Dissertação de mestrado, Swiss Federal Institute of Tecnology Zurich.
- Kolodziej, K. W. & Hjelm, J. (2006). *Local Positioning Systems: LBS Applications and Services*. CRC Press, erste edição.
- Kontkanen, P.; Myllymaki, P.; Roos, T.; Tirri, H.; Valtonen, K. & Wettig, H. (2004). Topics in probabilistic location estimation in wireless networks. Em *Personal, Indoor and Mobile Radio Communications, 2004. PIMRC 2004. 15th IEEE International Symposium on*, volume 2, pp. 1052--1056 Vol.2.
- Kotsiantis, S. B. (2007). Supervised machine learning: A review of classification techniques. Em *Proceedings of the 2007 conference on Emerging Artificial Intelligence Applications in Computer Engineering: Real Word AI Systems with Applications in eHealth, HCI, Information Retrieval and Pervasive Technologies*, pp. 3--24, Amsterdam, The Netherlands, The Netherlands. IOS Press.

- Ladd, A.; Bekris, K.; Marceau, G.; Rudys, A.; Wallach, D. & Kavraki, L. (2002). Using wireless ethernet for localization. Em *Intelligent Robots and Systems, 2002. IEEE/RSJ International Conference on*, volume 1, pp. 402--408 vol.1.
- Ladd, A.; Bekris, K.; Rudys, A.; Wallach, D. & Kavraki, L. (2004). On the feasibility of using wireless ethernet for indoor localization. *Robotics and Automation, IEEE Transactions on*, 20(3):555--559.
- Langendoen, K. & Reijers, N. (2005). Distributed localization algorithms. Em Zurawski, R., editor, *Embedded Systems Handbook*. CRC press.
- Larranaga, J.; Muguira, L.; Lopez-Garde, J.-M. & Vazquez, J.-I. (2010). An environment adaptive zigbee-based indoor positioning algorithm. Em *Indoor Positioning and Indoor Navigation (IPIN), 2010 International Conference on*, pp. 1--8.
- Lau, S.-Y.; Lin, T.-H.; Huang, T.-Y.; Ng, I.-H. & Huang, P. (2009). A measurement study of zigbee-based indoor localization systems under rf interference. Em *Proceedings of the 4th ACM international workshop on Experimental evaluation and characterization*, WINTECH '09, pp. 35--42, New York, NY, USA. ACM.
- Lee, D. L. & Chen, Q. (2007). A model-based wifi localization method. Em *Proceedings of the 2nd international conference on Scalable information systems*, InfoScale '07, pp. 40:1--40:7, ICST, Brussels, Belgium, Belgium. ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering).
- Li, X.; Pahlavan, K.; Latva-aho, M. & Ylianttila, M. (2000). Comparison of indoor geolocation methods in dsss and ofdm wireless lan systems. Em *Vehicular Technology Conference, 2000. IEEE-VTS Fall VTC 2000. 52nd*, volume 6, pp. 3015--3020 vol.6.
- Liu, H.; Darabi, H.; Banerjee, P. & Liu, J. (2007). Survey of wireless indoor positioning techniques and systems. *Systems, Man, and Cybernetics, Part C: Applications and Reviews, IEEE Transactions on*, 37(6):1067--1080.
- Malekitabar, A.; Aghababa, H.; Radfar, M. & Khalaj, B. (2005). Minimizing the error of time difference of arrival method in mobile networks. Em *Wireless and Optical Communications Networks, 2005. WOCN 2005. Second IFIP International Conference on*, pp. 328--332.
- Marsland, S. (2011). *Machine Learning: An Algorithmic Perspective*. Taylor & Francis.

- Martin, E.; Vinyals, O.; Friedland, G. & Bajcsy, R. (2010). Precise indoor localization using smart phones. Em *Proceedings of the international conference on Multimedia*, MM '10, pp. 787--790, New York, NY, USA. ACM.
- Moura, A. I. (2007). Wbls: um sistema de localização de dispositivos móveis em redes wi-fi. Dissertação de mestrado, Universidade de São Paulo.
- Ni, L. M.; Liu, Y.; Lau, Y. C. & Patil, A. P. (2004). Landmarc: indoor location sensing using active rfid. *Wireless Networks - Special issue: Pervasive computing and communications*, 10(6):701--710.
- Osório, R. M. M. M. (2011). Sistema de identificação e localização baseado em dispositivos de comunicações sem fios. Dissertação de mestrado, Faculdade de Engenharia da Universidade do Porto.
- Pahlavan, K.; Li, X. & Makela, J.-P. (2002). Indoor geolocation science and technology. *Communications Magazine, IEEE*, 40(2):112--118.
- Peterson, B. B.; Kmiecik, C.; Hartnett, R.; Thompson, P. M. & Mendom, J. (1998). Spread spectrum indoor geolocation. *NAVIGATION*, 45(2):97--102.
- Popov, L.; of Technology. Dept. of Electrical Engineering, M. I. & Science, C. (2008). inav : a hybrid approach to wifi localization and tracking of mobile devices. Dissertação de mestrado, Massachusetts Institute of Technology, Department of Electrical Engineering and Computer Science.
- Rappaport, T. (2002). *Wireless communications: principles and practice*. Prentice Hall communications engineering and emerging technologies series. Prentice Hall PTR.
- Rodrigues, M. L. (2011). Localização em ambientes internos utilizando múltiplas tecnologias sem fio. Dissertação de mestrado, Universidade Federal de Minas Gerais. Departamento de Ciência da Computação.
- Rodriguez, M.; Pece, J. P. & Escudero, C. J. (2005). In-building location using bluetooth. Em *in In Proceedings of the International Workshop on Wireless Ad Hoc Networks*.
- Röhrig, C. & Müller, M. (2009). Indoor location tracking in non-line-of-sight environments using a ieee 802.15.4a wireless network. Em *Proceedings of the 2009 IEEE/RSJ international conference on Intelligent robots and systems*, IROS'09, pp. 552--557, Piscataway, NJ, USA. IEEE Press.

- Roos, T.; Myllymäki, P.; Tirri, H.; Misikangas, P. & Sievänen, J. (2002). A probabilistic approach to wlan user location estimation. *International Journal of Wireless Information Networks*, 9(3):155--164.
- Saha, S.; Chaudhuri, K.; Sanghi, D. & Bhagwat, P. (2003). Location determination of a mobile device using ieee 802.11b access point signals. Em *Wireless Communications and Networking, 2003. WCNC 2003. 2003 IEEE*, volume 3, pp. 1987--1992 vol.3.
- Samama, N. (2008). *Global positioning: technologies and performance*. Wiley survival guides in engineering and science. Wiley-Interscience.
- Santos, D.; Perkusich, A. & Almeida, H. O. (2011). Infraestrutura para o Desenvolvimento de Aplicações Pervasivas Cientes de Redes Sociais. Em *XXVI Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos*, p. , Campo Grande, MS.
- Satyanarayanan, M. (2001). Pervasive computing: vision and challenges. *Personal Communications, IEEE*, 8(4):10--17.
- Seco, F.; Jimenez, A.; Prieto, C.; Roa, J. & Koutsou, K. (2009). A survey of mathematical methods for indoor localization. Em *Intelligent Signal Processing, 2009. WISP 2009. IEEE International Symposium on*, pp. 9--14.
- Siddiqi, S.; Sukhatme, G. S. & Howard, A. (2003). Experiments in Monte-Carlo Localization using WiFi Signal Strength. Em *Proceedings of the International Conference on Advanced Robotics*, Coimbra, Portugal.
- Smailagic, A. & Kogan, D. (2002). Location sensing and privacy in a context-aware computing environment. *Wireless Communications, IEEE*, 9(5):10--17.
- Tanenbaum, A. (2002). *Computer Networks*. Prentice Hall Professional Technical Reference, 4th edição.
- Torrieri, D. (1984). Statistical theory of passive location systems. *Aerospace and Electronic Systems, IEEE Transactions on*, AES-20(2):183--198.
- Tseng, Y.-C.; Wu, S.-L.; Liao, W.-H. & Chao, C.-M. (2001). Location awareness in ad hoc wireless mobile networks. *Computer*, 34(6):46--52.
- Vapnik, V. N. (1995). *The nature of statistical learning theory*. Springer-Verlag New York, Inc., New York, NY, USA.

- Want, R. (2006). An introduction to rfid technology. *Pervasive Computing, IEEE*, 5(1):25--33.
- Want, R.; Hopper, A.; Falcão, V. & Gibbons, J. (1992). The active badge location system. *ACM Trans. Inf. Syst.*, 10(1):91--102.
- Want, R. & Schilit, B. (2001). Expanding the horizons of location-aware computing. *Computer*, 34(8):31--34.
- Ward, A.; Jones, A. & Hopper, A. (1997). A new location technique for the active office. *Personal Communications, IEEE*, 4(5):42--47.
- Wassi, G.; Despins, C.; Grenier, D. & Nerguizian, C. (2005). Indoor location using received signal strength of ieee 802.11b access point. Em *Electrical and Computer Engineering, 2005. Canadian Conference on*, pp. 1367--1370.
- Weiss, A. (2003). On the accuracy of a cellular location system based on rss measurements. *Vehicular Technology, IEEE Transactions on*, 52(6):1508--1518.
- Wettschereck, D.; Aha, D. W. & Mohri, T. (1997). A review and empirical evaluation of feature weighting methods for aclass of lazy learning algorithms. *Artif. Intell. Rev.*, 11(1-5):273--314.
- Witten, I.; Frank, E. & Hall, M. (2011). *Data Mining: Practical Machine Learning Tools and Techniques: Practical Machine Learning Tools and Techniques*. The Morgan Kaufmann Series in Data Management Systems. Elsevier Science.
- Xiang, Z.; Song, S.; Chen, J.; Wang, H.; Huang, J. & Gao, X. (2004). A wireless lan-based indoor positioning technology. *IBM Journal of Research and Development*, 48(5.6):617--626.
- Yang, H. & Yang, S.-H. (2009). Connectionless indoor inventory tracking in zigbee rfid sensor network. Em *Industrial Electronics, 2009. IECON '09. 35th Annual Conference of IEEE*, pp. 2618--2623.
- Yang, Z.; Wu, C. & Liu, Y. (2012). Locating in fingerprint space: wireless indoor localization with little human intervention. Em *Proceedings of the 18th annual international conference on Mobile computing and networking*, Mobicom '12, pp. 269--280, New York, NY, USA. ACM.
- Yao, Q.; Wang, F.-Y.; Gao, H.; Wang, K. & Zhao, H. (2007). Location estimation in zigbee network based on fingerprinting. Em *Vehicular Electronics and Safety, 2007. ICVES. IEEE International Conference on*, pp. 1--6.

- Youssef, M. & Agrawala, A. (2004). Handling samples correlation in the horus system. Em *INFOCOM 2004. Twenty-third Annual Joint Conference of the IEEE Computer and Communications Societies*, volume 2, pp. 1023--1031 vol.2.
- Youssef, M. A.; Agrawala, A. & Shankar, A. U. (2003). Wlan location determination via clustering and probability distributions. Em *Proceedings of the First IEEE International Conference on Pervasive Computing and Communications*, PERCOM '03, pp. 143--, Washington, DC, USA. IEEE Computer Society.
- Zhang, G. (2000). Neural networks for classification: a survey. *Systems, Man, and Cybernetics, Part C: Applications and Reviews, IEEE Transactions on*, 30(4):451--462.
- Zheng, J. & Jamalipour, A. (2009). *Wireless Sensor Networks: A Networking Perspective*. Wiley.